

Prédiction d'indicateurs des marchés financiers à partir des données de dépenses publiques ouvertes : une approche par machine learning

Abdellah Elyamine DALI BRAHAM

ECE Paris — MSc Data Management & Intelligence Artificielle

Mémoire de fin d'études

Encadrante : Dr Yosra Hajjaji

Octobre 2026

Remerciements

Je remercie d'abord ma famille, qui m'a accompagné et soutenu tout au long de ma vie et de mes études, de l'Algérie jusqu'à Paris. Ce mémoire leur doit beaucoup.

Je remercie également mon encadrante, Dr Yosra Hajjaji, pour son suivi et ses conseils, ainsi que l'équipe pédagogique du MSc Data Management & Intelligence Artificielle de l'ECE Paris.

Déclaration d'utilisation de l'intelligence artificielle

Conformément au guide de rédaction de l'ECE, je déclare avoir utilisé un outil d'intelligence artificielle générative (Claude, d'Anthropic) comme assistant pour la programmation, la relecture du code et la rédaction. Le choix du sujet, de la problématique et du périmètre et les décisions de méthode relèvent de l'auteur, qui a relu l'ensemble du texte et en assume la responsabilité. Les chiffres cités ont été vérifiés sur les fichiers de résultats.

Résumé

Ce mémoire cherche à savoir si les données ouvertes de dépenses publiques permettent de prévoir les marchés financiers. Nous utilisons les situations mensuelles budgétaires de l'État français (2013-2026), en tenant compte de leur délai de publication de deux mois, pour prévoir le mois suivant trois indicateurs : la variation du spread OAT-Bund à 10 ans, la variation du taux OAT à 10 ans et le rendement du CAC 40. Nous comparons un modèle qui n'utilise que des variables de marché et macroéconomiques à un modèle qui ajoute les dépenses, avec trois méthodes (régression Ridge, forêt aléatoire, XGBoost), une validation glissante et des tests de Diebold-Mariano. Dix-neuf extensions, dont un panel de cinq pays européens, complètent l'analyse.

Nous ne trouvons aucune preuve que les dépenses améliorent la prévision : aucune des 168 comparaisons n'est significative après correction pour tests multiples. Aucun modèle ne bat la moyenne historique, et pour les taux, la prévision « pas de variation » fait mieux que tous les modèles, même si l'écart est rarement significatif. Des contrôles avec un signal fictif et avec des variables de bruit montrent que notre dispositif aurait le plus souvent détecté un effet fort, mais pas forcément un effet faible. Enfin, nous montrons qu'un R^2 très élevé sur le niveau du spread, comme dans la littérature récente, ne suffit pas : les modèles perdent face à la simple reconduction du spread du mois précédent.

Mots-clés : dépenses publiques, données ouvertes, spread souverain, prévision, machine learning, validation glissante, marchés efficients.

Sommaire

Remerciements.....	2
Déclaration d'utilisation de l'intelligence artificielle.....	3
Résumé.....	4
Sommaire.....	5
Liste des tableaux.....	9
Liste des figures.....	10
Liste des abréviations.....	11
Glossaire.....	11
Introduction générale.....	13
Contexte.....	13
Problématique.....	13
Objectif et démarche.....	14
Apports.....	14
Plan du mémoire.....	15
Chapitre 1 – État de l'art.....	16
Introduction du chapitre.....	16
1.1 Cadre théorique : ce que l'on peut attendre.....	17
1.2 Finances publiques et spreads souverains en zone euro.....	18
1.3 Machine learning et prévision des spreads.....	21
1.4 Données ouvertes et précautions de méthode.....	23

1.5 Synthèse et positionnement du mémoire.....	25
Chapitre 2 – Données et méthodologie.....	29
Introduction du chapitre.....	29
2.1 Sources des données.....	29
2.2 Construction du jeu de données.....	31
2.3 Variables cibles et stationnarité.....	34
2.4 Variables explicatives.....	35
2.5 Modèles retenus.....	36
2.6 Protocole d'évaluation.....	38
2.7 Extensions datées avant exécution et correction des tests multiples.....	41
2.8 Considérations éthiques.....	44
Chapitre 3 – Résultats.....	46
3.1 Statistiques descriptives.....	46
3.2 Modèles principaux.....	47
3.3 Solidité des résultats.....	49
3.4 Importance des variables.....	50
3.5 Extensions sur les données françaises.....	51
3.6 Panel européen et marche aléatoire (E15 à E18).....	54
3.7 Synthèse : état des hypothèses.....	55
Chapitre 4 – Discussion.....	56
4.1 Réponse à la problématique.....	56

4.2 Pourquoi les dépenses n'aident pas : trois pistes.....	56
4.3 Ce que le résultat négatif veut dire, et ce qu'il ne veut pas dire.....	58
4.4 Retour sur les modèles.....	59
4.5 Comparaison avec la littérature.....	60
4.6 Implications.....	62
4.7 Limites.....	63
4.8 Recherches futures.....	64
Conclusion générale.....	66
Principaux résultats.....	66
Apports.....	66
Limites.....	67
Perspectives.....	67
Références.....	68
Sources en ligne.....	70
Annexes.....	71
Annexe A – Variables des modèles principaux.....	71
Annexe B – Détail des extensions E1 à E20.....	71
Annexe C – Sensibilité à la graine aléatoire.....	85
Annexe D – Contrôle négatif : dépenses contre variables de bruit.....	85
Annexe E – Robustesse au décalage de publication.....	86
Annexe F – Code et reproductibilité.....	86

Liste des tableaux

Tableau 1.1 – Principaux travaux recensés.....	25
Tableau 2.1 – Sources des données.....	29
Tableau 2.2 – Soldes annuels reconstitués.....	33
Tableau 2.3 – Variables cibles.....	34
Tableau 2.4 – Test de stationnarité (Dickey-Fuller augmenté).....	34
Tableau 2.5 – Jeux de variables emboîtés.....	35
Tableau 2.6 – Modèles comparés.....	36
Tableau 2.7 – Mesures de performance.....	39
Tableau 2.8 – Extensions testées.....	42
Tableau 3.1 – Statistiques des variables cibles (mars 2014 – juillet 2026, 149 mois).....	46
Tableau 3.2 – R^2 hors échantillon par rapport à la moyenne historique (%), janvier 2020 – juillet 2026.....	47
Tableau 3.3 – Tests de Diebold-Mariano (p-values bilatérales).....	48
Tableau 3.4 – Contrôle positif : part des tirages où le signal est retrouvé (Ridge, 10 tirages par valeur de ρ , 1 pour $\rho = 1$).....	49
Tableau 3.5 – Part de l'importance SHAP des sept variables ajoutées à M0 (%).....	50
Tableau 3.6 – Meilleur R^2 hors échantillon sans / avec dépenses, par extension (%).....	52
Tableau 3.7 – E16 : niveau du spread, comparaison à la marche aléatoire (avec finances publiques).....	54
Tableau 3.8 – État des hypothèses.....	55
Tableau A.1 – Variables des jeux emboîtés M0, M1 et M2.....	71

Tableau B.1 – Résultats des 210 comparaisons.....	71
Tableau C.1 – R^2 hors échantillon (%) selon la graine.....	85
Tableau D.1 – Gain de R^2 par rapport à M0 (points) : vraies dépenses et sept variables de bruit.....	85
Tableau E.1 – Modèles principaux avec un décalage budgétaire de 1, 2 et 3 mois.....	86

Liste des figures

Figure 3.1 – Distribution des trois cibles.....	47
Figure 3.2 – RMSE relatif à la moyenne historique.....	49
Figure 3.3 – Importance SHAP des variables.....	51
Figure 3.4 – Synthèse des extensions.....	53

Liste des abréviations

Abréviation	Signification
ACP	Analyse en composantes principales
ADF	Test de Dickey-Fuller augmenté
BCE	Banque centrale européenne
BH	Correction de Benjamini-Hochberg
BTP	Bâtiment et travaux publics
CAC 40	Indice des 40 principales capitalisations de la Bourse de Paris
DGFîP	Direction générale des Finances publiques
DM	Test de Diebold-Mariano
EPU	Economic Policy Uncertainty (indice d'incertitude de politique économique)
FMI	Fonds monétaire international
FRED	Base de données de la Federal Reserve Bank of St. Louis
HLN	Correction de Harvey, Leybourne et Newbold du test DM
IA	Intelligence artificielle
INSEE	Institut national de la statistique et des études économiques
IPCH	Indice des prix à la consommation harmonisé
LFI	Loi de finances initiale
MAE	Erreur absolue moyenne
ML	Machine learning (apprentissage automatique)
OAT	Obligation assimilable du Trésor (emprunt d'État français)
OCDE	Organisation de coopération et de développement économiques
pb	Point de base (0,01 point de pourcentage)
PIB	Produit intérieur brut
RF	Forêt aléatoire (random forest)
RMSE	Racine de l'erreur quadratique moyenne
SHAP	SHapley Additive exPlanations (mesure d'importance des variables)
SMB	Situation mensuelle budgétaire de l'État
VAR	Modèle vectoriel autorégressif
VIX	Indice de volatilité implicite du S&P 500
XGB	XGBoost (gradient boosting)

Glossaire

Spread OAT–Bund. Écart entre le taux de l'emprunt d'État français à 10 ans et celui de l'emprunt allemand de même durée. Il mesure le supplément de rendement exigé par les investisseurs pour prêter à la France plutôt qu'à l'Allemagne.

R² hors échantillon. Part de l'erreur de la moyenne historique que le modèle évite, sur des données qu'il n'a pas vues. Positif : le modèle fait mieux que la moyenne ; négatif : il fait moins bien.

Marche aléatoire (variation nulle). Préviction naïve selon laquelle la valeur du mois prochain sera égale à celle du mois en cours.

Validation glissante. Méthode d'évaluation où le modèle est réestimé chaque mois avec les seules données passées, puis prévoit le mois suivant.

Biais d'anticipation (look-ahead bias). Erreur qui consiste à utiliser une information qui n'était pas encore publiée à la date de la prévision.

Contrôle positif / négatif. Test du dispositif avec une variable fictive construite pour contenir un signal (positif), ou avec des variables de pur bruit (négatif).

Puissance d'un test. Probabilité qu'un test détecte un effet qui existe réellement.

Introduction générale

Contexte

Les finances publiques françaises sont redevenues un sujet central pour les marchés. Le déficit du budget de l'État a atteint 173 milliards d'euros en 2023 et 156 milliards en 2024. Entre 2023 et 2025, les agences de notation ont abaissé cinq fois la note de la France. Sur les marchés, l'écart de taux entre la France et l'Allemagne à 10 ans (le spread OAT–Bund), qui mesure le supplément de rendement exigé pour prêter à la France, est passé d'environ 26 points de base en 2016 à plus de 80 points de base début 2025. En juin 2024, l'annonce de la dissolution de l'Assemblée nationale l'a fait monter de près de 16 points de base en un mois.

Dans le même temps, les données publiques sont de plus en plus ouvertes. Le ministère de l'Économie publie chaque mois la situation budgétaire de l'État, en séries longues ouvertes depuis 2013 : dépenses de personnel, de fonctionnement, d'investissement, d'intervention, charge de la dette, recettes. Ces séries sont gratuites, détaillées et disponibles environ deux mois après la fin de chaque mois.

Enfin, les méthodes de machine learning sont de plus en plus utilisées pour prévoir les variables financières. Des travaux récents annoncent de très bonnes performances pour la prévision des spreads souverains européens [14].

Problématique

Ces trois éléments conduisent à une question simple : **peut-on prédire des indicateurs des marchés financiers à partir des données de dépenses publiques ouvertes, en utilisant des techniques de machine learning ?**

La réponse n'a rien d'évident. D'un côté, les études européennes montrent que les finances publiques expliquent une partie du niveau des spreads, surtout en période de crise [1]. De l'autre, la théorie des marchés efficients [22] et les travaux sur l'anticipation des dépenses

[35] suggèrent qu’une information connue, ou prévisible, est déjà dans les prix. Un résultat négatif est donc aussi plausible qu’un résultat positif, et les deux seraient instructifs.

Objectif et démarche

Nous étudions trois indicateurs, plus ou moins exposés au risque souverain français : la variation du spread OAT–Bund à 10 ans, la variation du taux OAT à 10 ans et le rendement du CAC 40. Pour chacun, nous prévoyons la valeur du mois suivant, sur la période 2014-2026.

La démarche repose sur une comparaison directe. Un premier modèle n’utilise que des variables de marché et macroéconomiques. Un second ajoute les dépenses de l’État. Si les dépenses contiennent une information utile, le second modèle doit mieux prévoir. Nous testons trois méthodes (régression Ridge, forêt aléatoire, XGBoost), toujours évaluées sur des mois qu’elles n’ont pas vus, avec des tests statistiques pour juger les écarts.

Une attention particulière est portée à la rigueur de l’évaluation. Les données budgétaires sont décalées de leur délai réel de publication, pour ne jamais utiliser une information qui n’était pas encore connue. Dix-neuf extensions testent d’autres horizons, d’autres cibles et un panel de cinq pays européens. Enfin, des contrôles avec un signal fictif et avec des variables de bruit permettent de savoir ce que notre dispositif est capable de détecter.

Apports

Ce travail apporte trois choses. Il isole l’apport des dépenses publiques, que les études de prévision mélangent d’habitude à des centaines, voire des milliers, d’autres variables. Il utilise les données détaillées d’exécution du budget français, alors que la France est peu étudiée dans cette littérature. Et il montre, chiffres à l’appui, qu’une très bonne performance apparente peut cacher une prévision moins bonne que la plus simple des références.

Plan du mémoire

Le chapitre 1 présente l'état de l'art : le cadre théorique, les travaux européens sur les finances publiques et les spreads, et l'usage du machine learning pour les prévoir. Le chapitre 2 décrit les données et la méthodologie. Le chapitre 3 présente les résultats, sans les interpréter. Le chapitre 4 les discute : réponse à la problématique, explications possibles, comparaison avec la littérature, implications, limites et pistes de recherche. La conclusion résume les apports du travail.

Chapitre 1 – État de l’art

Introduction du chapitre

Ce chapitre fait le point sur ce que l’on sait déjà. Il part d’une question simple : quelqu’un a-t-il déjà utilisé les données ouvertes de dépenses de l’État français, avec des méthodes de machine learning, pour prévoir les marchés financiers ? À notre connaissance, non. Les sections qui suivent montrent pourquoi ce vide existe et pourquoi il mérite d’être exploré.

Nous étudions trois indicateurs, plus ou moins liés aux finances publiques :

- **Le spread OAT–Bund à 10 ans** : l’écart entre le taux auquel la France emprunte sur dix ans (OAT, Obligation assimilable du Trésor) et celui de l’Allemagne (Bund). Comme la politique monétaire est la même pour les deux pays, cet écart mesure surtout le risque propre à la France.
- **Le taux OAT à 10 ans** : le coût d’emprunt de l’État français. Il dépend à la fois des finances publiques et de la politique de la BCE.
- **Le rendement mensuel du CAC 40** : l’évolution de la valeur des grandes entreprises cotées à Paris.

Ces trois indicateurs vont du plus exposé au moins exposé aux finances publiques. Les comparer permet de voir où les dépenses apportent, ou non, de l’information.

Notre terrain est la France, dans la zone euro. **Nous donnons donc la priorité aux études européennes.** Les grands travaux américains restent utiles, mais surtout comme cadre théorique ou comme référence de méthode : nous les présentons plus brièvement.

La section 1.1 pose le cadre théorique. La section 1.2 présente les travaux européens sur le lien entre finances publiques et spreads. La section 1.3 porte sur le machine learning appliqué à la prévision des spreads. La section 1.4, plus courte, traite des données ouvertes et des précautions de méthode. La section 1.5 fait la synthèse et formule nos hypothèses.

1.1 Cadre théorique : ce que l'on peut attendre

La théorie ne promet pas grand-chose à une prévision fondée sur des données budgétaires publiques. Trois travaux, généraux même s'ils portent surtout sur les États-Unis, en donnent les raisons.

1.1.1 Dépenses publiques et taux : deux visions.

Dans la vision keynésienne, une hausse des dépenses financée par l'emprunt augmente la demande de fonds et fait monter les taux d'intérêt. Elle peut alors évincer une partie de l'investissement privé. À l'inverse, l'équivalence ricardienne de Barro [8] suppose que les ménages anticipent les impôts futurs et épargnent davantage, ce qui annule l'effet sur les taux. La théorie ne tranche donc pas : la question est empirique.

1.1.2 L'efficience des marchés.

Selon l'hypothèse d'efficience, dans sa forme semi-forte, les prix reflètent déjà toute l'information publique [22]. Aucune donnée publique ne devrait alors permettre de prévoir de façon régulière les variations des prix.

Cela nous concerne directement. Les situations budgétaires de l'État sont publiques. Si le marché obligataire est efficient, elles sont intégrées dans le spread dès leur publication, et elles ne servent plus à prévoir le mois suivant.

1.1.3 Les dépenses sont anticipées.

Ramey [35] montre que les chocs de dépenses publiques mesurés par les modèles classiques sont en partie connus à l'avance. Une dépense est annoncée, votée, puis exécutée des mois plus tard. La mesurer au moment de l'exécution, c'est la mesurer trop tard.

C'est exactement le type de données que nous utilisons : l'exécution mensuelle du budget. Si les marchés réagissent aux annonces, ces données apportent peu d'information nouvelle. Ramey nous donne donc une raison claire de s'attendre à un pouvoir prédictif faible.

1.1.4 Peu de prédicteurs résistent hors échantillon.

Welch et Goyal [36] testent les variables les plus connues pour prévoir le rendement des actions. La plupart semblent fonctionner sur les données qui ont servi à les estimer. Mais sur des données nouvelles, elles font rarement mieux qu'une simple moyenne historique. Campbell et Thompson [16] nuancent ce constat : avec quelques contraintes de bon sens, certains prédicteurs battent légèrement la moyenne, et même un petit gain peut avoir de la valeur.

1.1.5 Ce que nous en retenons.

- Un pouvoir prédictif faible, voire nul, est plausible dès le départ. Un résultat négatif serait cohérent avec Fama et Ramey, et il aurait un sens.
- Il faut évaluer les modèles hors échantillon, sur des mois qu'ils n'ont jamais vus.
- La référence à battre est simple : la moyenne historique (et, pour les taux, la variation nulle). Un modèle qui ne la bat pas n'a pas de pouvoir prédictif utile par rapport à cette référence.

1.2 Finances publiques et spreads souverains en zone euro

En Europe, plusieurs travaux montrent que les finances publiques expliquent une partie des spreads face à l'Allemagne. Mais ils cherchent à expliquer, pas à prévoir, et l'effet change beaucoup selon les périodes.

1.2.1 Pourquoi le spread.

Dans une union monétaire, tous les pays ont la même banque centrale. L'écart de taux avec l'Allemagne reflète donc surtout ce qui est propre à chaque État : son risque de crédit et la liquidité de sa dette. C'est pour cela que le spread est la variable la plus logique pour mesurer l'effet des finances publiques d'un pays de la zone euro.

1.2.2 Ce que montrent les travaux européens.

Bernoth, von Hagen et Schuknecht [11] étudient les spreads des obligations européennes face à l'Allemagne. La dette, le déficit et la charge de la dette en expliquent une partie, y compris après l'entrée dans l'euro. L'aversion au risque mondiale renforce cet effet.

Attinasi, Checherita et Nickel [4] cherchent ce qui a fait monter les spreads pendant la crise, de fin juillet 2007 à fin mars 2009. Ils trouvent trois moteurs : l'aversion au risque internationale, la liquidité des marchés obligataires et les positions budgétaires attendues. Les annonces de plans de sauvetage bancaire ont aussi pesé. Détail important pour nous : c'est l'annonce elle-même qui a compté, et non le montant engagé, dont l'effet n'est pas significatif.

Afonso, Arghyrou et Kontonikas [1] couvrent la zone euro de 1999 à 2010. Les marchés tiennent compte des déficits attendus sur toute la période, mais les sanctionnent beaucoup plus fort après mars 2009. La dette, elle, ne compte vraiment qu'à partir de la crise des dettes souveraines. **L'effet des finances publiques sur les spreads n'est donc pas stable dans le temps** : il apparaît surtout en période de tension.

Favero [23] est l'un des rares à **prévoir** les spreads, et non seulement à les expliquer. Avec un modèle économétrique (un VAR global), il fait dépendre le spread de chaque pays de ceux des autres, pondérés selon la ressemblance de leurs finances publiques. Son modèle prévoit mieux, hors échantillon, que les spécifications classiques.

1.2.3 Le cas français.

Les études consacrées à la France sont rares. Garlanda-Longueville [25] consacre un chapitre de sa thèse aux allocutions du président de la République pendant la crise du Covid (mars 2020 à décembre 2021), qui contenaient des engagements budgétaires. Avec des données quotidiennes, elle montre que ces annonces ont en général fait monter le CAC 40 et baisser le spread France–Allemagne. Fait notable : les communiqués annonçant à l'avance une

allocation ont un effet plus significatif que l'allocation elle-même. Ce résultat va dans le sens de Ramey [35] : le marché réagit aux annonces.

L'actualité récente le confirme. Après la dissolution de l'Assemblée nationale en juin 2024, l'incertitude sur la trajectoire budgétaire a nettement élargi le spread OAT–Bund : dans nos données, sa moyenne mensuelle augmente de 15,5 points de base en juin 2024, l'une des plus fortes hausses de la période.

1.2.4 Les travaux fondateurs, surtout américains.

Ces travaux européens s'appuient sur une littérature plus ancienne, surtout américaine, que nous résumons brièvement. Blanchard et Perotti [13] proposent une méthode de référence pour isoler les chocs budgétaires, et trouvent qu'une hausse des dépenses réduit l'investissement privé. Laubach [31] estime qu'un point de PIB de déficit prévu en plus fait monter les taux longs américains d'environ 25 points de base. Afonso et Sousa [2] montrent que les chocs de dépenses pèsent sur le prix des actions, et Ardagna [3] que les fortes consolidations budgétaires dans l'OCDE s'accompagnent d'une baisse des taux et d'une hausse des actions.

1.2.5 Ce que nous en retenons.

- Le spread OAT–Bund est la cible la plus directement liée aux finances publiques françaises.
- L'aversion au risque et la liquidité comptent beaucoup : elles doivent être dans le modèle comme variables de contrôle.
- L'effet des finances publiques dépend de la période. Il faudra regarder séparément les périodes calmes et agitées.

- Presque tous ces travaux utilisent des modèles linéaires, des données annuelles ou trimestrielles, et cherchent à expliquer plutôt qu'à prévoir. Aucun ne teste le machine learning sur des données budgétaires mensuelles.

1.3 Machine learning et prévision des spreads

Le machine learning améliore souvent les prévisions financières, surtout quand les relations entre variables ne sont pas linéaires. Appliqué aux spreads européens, il donne de bons résultats. Mais dans ces travaux, c'est surtout le passé du spread qui fait le travail, et l'apport des finances publiques n'est jamais isolé.

1.3.1 Les travaux européens.

Belly et al. [9] utilisent le machine learning pour évaluer le risque souverain de dix pays de la zone euro, sur des données mensuelles de 2004 à 2019, en niveau et en variation mensuelle. Leurs méthodes suivent la dynamique des spreads bien mieux que les modèles économétriques habituels. Le sentiment des actualités financières, le risque de sortie de l'euro et la communication de la BCE ressortent comme des déterminants importants.

Bouillot, Candelon et Kool [14] sont les plus proches de notre travail. Ils prévoient à un mois le spread à 10 ans face au Bund de dix pays de la zone euro, dont la France, sur des données mensuelles de décembre 2008 à février 2025. Ils comparent treize méthodes sur près de 5 000 variables (4 948 séries), dont des variables de finances publiques. XGBoost donne les meilleures prévisions : sur 2020-2025, son erreur (RMSE) est de 4 à 8 points de base pour les pays du cœur de la zone euro, et de 7,3 points de base pour la France. La cible est le niveau du spread. Dans la version du document de travail que nous avons consultée, les modèles sont comparés entre eux, à la moyenne et à des régressions linéaires, mais pas à la prévision naïve « spread du mois précédent ». Le résumé d'une version plus récente indique que l'AR(1) et la

marché aléatoire ont des erreurs plus faibles que les modèles de machine learning dans chaque pays, quand les modèles sont réestimés à chaque date.

Deux de leurs résultats comptent pour nous. D’abord, **c’est le spread passé qui domine les prévisions**, complété par les conditions financières, les prix et les indicateurs de marché mondiaux. Les finances publiques y pèsent très peu : parmi les cinq variables les plus importantes de chacun des dix pays (50 au total), une seule relève des finances publiques. Ensuite, la France et la Belgique se détachent des autres pays du cœur de la zone euro à partir de mi-2024.

Enfin, Barbier-Gauchard et Sofianos [7] appliquent le machine learning aux finances publiques elles-mêmes. Ils prévoient la dette publique de 17 pays de la zone euro, et XGBoost y fait mieux que les projections de la Commission européenne et du FMI.

1.3.2 Le contexte américain, en bref.

Ces travaux européens suivent une littérature américaine plus large. Gu, Kelly et Xiu [28] montrent que les arbres de décision et les réseaux de neurones prévoient mieux les rendements des actions que les modèles linéaires, grâce aux effets non linéaires. Bianchi, Büchner et Tamoni [12] trouvent le même type de gain pour les obligations d’État. En macroéconomie, Medeiros et al. [34] et Goulet Coulombe et al. [27] montrent que les forêts aléatoires prévoient bien l’inflation, surtout en période d’incertitude.

1.3.3 Quels modèles avec peu de données.

Les modèles à base d’arbres, comme les forêts aléatoires [15] et XGBoost [17], fonctionnent bien sur des tableaux de données de taille moyenne. Le deep learning demande beaucoup plus d’observations : Fischer et Krauss [24] obtiennent de bons résultats avec des réseaux LSTM, mais sur des données quotidiennes de centaines d’actions pendant plus de vingt ans. Avec environ 150 mois, un tel modèle apprendrait surtout le bruit.

1.3.4 Ce que nous en retenons.

- Il faut comparer le machine learning à des références simples : la moyenne historique, la variation nulle et un modèle linéaire.
- Le spread passé, principal prédicteur chez Bouillot et al. [14], doit être dans tous les modèles. Sinon, on attribuerait aux dépenses ce qui vient en réalité du spread lui-même.
- La forêt aléatoire et XGBoost sont adaptés à notre volume de données ; le deep learning ne l'est pas.
- Aucun de ces travaux ne mesure séparément ce qu'apportent les dépenses publiques. C'est la question précise de ce mémoire.

1.4 Données ouvertes et précautions de méthode

Les données publiques ouvertes sont gratuites, officielles et régulières. Pour la prévision, elles posent pourtant trois problèmes : le délai de publication, les révisions et la forme des données.

1.4.1 Les données budgétaires ouvertes.

Janssen, Charalabidis et Zuiderwijk [30] rappellent que publier des données ne suffit pas à ce qu'elles soient utilisées : leur qualité, leur format et leur documentation comptent autant. En France, la loi pour une République numérique de 2016 fait de l'ouverture des données publiques la règle. Le ministère de l'Économie diffuse ainsi, sur data.economie.gouv.fr, la situation mensuelle budgétaire de l'État en séries longues depuis 2013 : dépenses par titre, recettes et solde.

Cette source a trois particularités. Les montants sont cumulés depuis janvier. Ils sont très saisonniers, par exemple l'impôt sur les sociétés, concentré sur quelques échéances. Et la

situation d'un mois M ne paraît qu'au début du mois $M+2$: celle de juin 2026 a été publiée le 4 août 2026.

1.4.2 Calendrier de publication et révisions.

Giannone, Reichlin et Small [26] montrent qu'une donnée n'apporte de l'information qu'à partir du moment où elle est publiée : son calendrier compte autant que son contenu. Croushore [18] ajoute que beaucoup de données sont révisées après leur première publication. Évaluer un modèle avec les chiffres définitifs surestime donc ses performances, puisque le prévisionniste n'avait que les chiffres provisoires. La situation budgétaire est concernée : le mois de décembre paraît d'abord en version provisoire.

Aux États-Unis, McCracken et Ng [33] ont construit FRED-MD, une base mensuelle de plus d'une centaine d'indicateurs macroéconomiques. Il n'existe pas d'équivalent français qui intègre l'exécution budgétaire.

1.4.3 Éviter de se tromper soi-même.

Bailey et al. [5] mettent en garde contre un piège fréquent : à force de tester des configurations sur les mêmes données, on finit toujours par en trouver une qui semble marcher, par hasard. Pour des séries temporelles, il faut aussi une validation glissante, où le modèle n'apprend que sur le passé. Enfin, un petit écart d'erreur entre deux modèles peut être dû au hasard : le test de Diebold et Mariano [20] permet de le vérifier.

1.4.4 Ce que nous en retenons.

- Les données budgétaires d'un mois ne peuvent servir qu'après leur publication : nous les décalons de deux mois.
- Les montants cumulés doivent être transformés pour enlever la saisonnalité.
- Les révisions seront discutées comme une limite.

- Construire un jeu de données mensuel français qui croise budget et marchés est déjà, en soi, une contribution.

1.5 Synthèse et positionnement du mémoire

À notre connaissance, aucun travail ne prévoit des indicateurs des marchés financiers français à partir des données ouvertes de dépenses publiques mensuelles avec du machine learning. Le tableau 1.1 résume les travaux clés, classés selon leur rôle dans ce mémoire.

Tableau 1.1 – Principaux travaux recensés

Rôle	Auteurs (année)	Pays et données	Méthode	Résultat principal	Limite pour ce mémoire
Noyau européen	Bouillot, Candelon et Kool [14]	10 pays de la zone euro dont la France ; mensuel, 2008-2025	13 méthodes de ML, XGBoost en tête	Prévision à un mois ; le spread passé domine	Apport des finances publiques non isolé (1 des 50 variables principales) ; cible en niveau, sans comparaison à la marche aléatoire dans la version consultée
Noyau européen	Belly et al. [9]	10 pays de la zone euro ; mensuel, 2004-2019	ML contre économétrie	Le ML suit mieux la dynamique des spreads	Pas centré sur les dépenses
Noyau européen	Favero [23]	Zone euro ; spreads	VAR global	Meilleure prévision hors échantillon que les modèles classiques	Linéaire, pas de données d'exécution
Noyau européen	Afonso, Arghyrou et Kontonikas [1]	Zone euro, 1999-2010	Panel	Déficits attendus sanctionnés ; dette prise en compte seulement après 2009	Explique, ne prévoit pas
Noyau européen	Bernoth, von Hagen et Schuknecht [11]	Europe ; spreads face à l'Allemagne	Panel	Dette et déficit expliquent une partie des spreads	Linéaire, données annuelles
Noyau européen	Attinasi, Checherita et Nickel [4]	Zone euro, 2007-2009	Panel dynamique	Risque, liquidité, positions budgétaires attendues et annonces de sauvetage bancaire expliquent les spreads	Période de crise seulement
Noyau européen	Garlanda-Longueville [25]	France ; annonces du Covid	Étude d'événements	Les annonces du président de la République font en général monter les	Annonces, pas dépenses exécutées

Rôle	Auteurs (année)	Pays et données	Méthode	Résultat principal	Limite pour ce mémoire
				actions et baisser le spread	
Noyau européen	Barbier-Gauchard et Sofianos [7]	17 pays de la zone euro ; dette publique	ML (XGBoost)	Prévoit mieux la dette que la Commission et le FMI	Cible budgétaire, pas financière
Cadre théorique	Fama [22]	Général (études surtout américaines)	Synthèse théorique et empirique	Les prix intègrent l'information publique	Ne porte pas sur les données budgétaires
Cadre théorique	Ramey [35]	États-Unis ; trimestriel	VAR, chocs narratifs	Les chocs de dépenses sont anticipés	Explique, ne prévoit pas
Cadre théorique	Welch et Goyal [36]	États-Unis ; actions	Régressions hors échantillon	Peu de prédicteurs battent la moyenne historique	Pas de ML, pas d'obligations
Méthode	Gu, Kelly et Xiu [28]	États-Unis ; actions	ML (arbres, réseaux de neurones)	Gain grâce à la non-linéarité	Pas de variables budgétaires
Méthode	Bianchi, Büchner et Tamoni [12]	États-Unis ; obligations d'État	ML, variables macroéconomiques	Meilleure prévision des rendements obligataires	Pas de données budgétaires, pas la France
Méthode	Giannone, Reichlin et Small [26]	États-Unis ; mensuel	Modèle à facteurs	Le calendrier de publication fixe la valeur d'une donnée	Cible : le PIB
Méthode	Croushore [18]	États-Unis ; données en temps réel	Synthèse	Les révisions faussent l'évaluation des modèles	Pas de marchés financiers

Source : élaboration de l'auteur.

1.5.1 Le vide identifié.

La littérature se partage en deux blocs qui se croisent peu :

- **Le bloc macro-budgétaire** relie finances publiques et taux souverains. Il utilise des modèles linéaires et des données annuelles ou trimestrielles, et il cherche à expliquer plutôt qu'à prévoir.
- **Le bloc machine learning** montre des gains de prévision sur les marchés financiers. Mais il n'utilise pas les données d'exécution budgétaire.

Un troisième constat s'ajoute : **la France est peu étudiée**. Six des quinze travaux du tableau portent uniquement sur les États-Unis. Un seul, Garlanda-Longueville [25], se concentre sur la France, et il porte sur les annonces, pas sur les dépenses exécutées. Même Bouillot et

al. [14] traitent la France comme un pays parmi dix. Pourtant, la question budgétaire française est devenue centrale pour les marchés : la note de la France a été abaissée cinq fois par les agences entre 2023 et 2025. Et ses données d'exécution budgétaire sont disponibles en séries longues ouvertes.

Bouillot, Candelon et Kool [14] commencent à rapprocher les deux blocs. Notre travail s'en distingue sur trois points :

- **Nous isolons l'apport des dépenses publiques.** Chez eux, les finances publiques sont mêlées à près de 5 000 variables. Ici, nous comparons explicitement le même modèle avec et sans dépenses.
- **Nous utilisons les données détaillées d'exécution du budget français**, par catégorie de dépense, en données ouvertes.
- **Nous comparons trois indicateurs** plus ou moins exposés au risque souverain : le spread, le taux OAT et le CAC 40.

1.5.2 Problématique et hypothèses.

Notre problématique est la suivante : **peut-on prédire des indicateurs des marchés financiers à partir des données de dépenses publiques ouvertes en utilisant des techniques de machine learning ?**

Concrètement, nous testons si les dépenses de l'État améliorent la prévision mensuelle de trois indicateurs : la variation du spread OAT–Bund à 10 ans, la variation du taux OAT à 10 ans et le rendement du CAC 40. L'apport est mesuré par rapport à des modèles qui n'utilisent que des variables de marché et macroéconomiques.

Nous formulons quatre hypothèses :

- **H1.** Pour au moins un des trois indicateurs, un modèle qui intègre les dépenses publiques prévoit mieux qu'un modèle qui n'utilise que les variables de contrôle.

- **H2.** L'apport des dépenses diminue du spread au taux OAT, puis au CAC 40, à mesure que l'indicateur est moins exposé au risque souverain.
- **H3.** Les modèles de machine learning (forêt aléatoire, XGBoost) prévoient mieux que les modèles linéaires.
- **H4.** Parmi les dépenses, la charge de la dette et les dépenses d'intervention sont les plus prédictives.

En suivant Fama [22] et Ramey [35], un rejet de H1 reste un résultat plausible, et il nous apprendrait quelque chose.

Chapitre 2 – Données et méthodologie

Introduction du chapitre

Ce chapitre explique d'où viennent nos données, comment nous les avons transformées et comment nous avons évalué les modèles. Tout le protocole répond à une seule contrainte : ne jamais donner au modèle une information qu'un investisseur n'aurait pas eue au moment de sa décision.

Nous présentons d'abord les sources (2.1), puis la construction du jeu de données mensuel (2.2). Viennent ensuite les variables à prédire (2.3) et les variables explicatives (2.4). La section 2.5 justifie le choix des modèles, et la section 2.6 décrit la façon dont nous les évaluons. Pour finir, la section 2.7 présente les variantes testées pour vérifier la solidité des résultats.

Le code et les données sont conservés dans un dépôt GitHub (accessible sur demande). Chaque tableau et chaque figure de ce mémoire peut donc être recalculé à partir des fichiers bruts.

2.1 Sources des données

Le sujet impose des données ouvertes. Toutes nos sources sont donc publiques et gratuites. Elles couvrent la période de janvier 2013 à août 2026, en fréquence mensuelle.

Tableau 2.1 – Sources des données

Donnée	Source	Fréquence	Usage
Situations mensuelles budgétaires de l'État (séries longues)	DGFiP, data.economie.gouv.fr	Mensuelle, cumul depuis janvier	Variables de dépenses, recettes et solde
Budget voté (lois de finances initiales)	DGFiP, data.economie.gouv.fr	Annuelle	Surprise budgétaire (extension E4)
Taux à 10 ans France (OAT) et Allemagne (Bund)	OCDE, via FRED	Mensuelle (moyenne)	Cibles (calcul du spread)
CAC 40	Yahoo Finance	Quotidienne, ramenée au dernier cours du mois	Cible et contrôle
Taux directeurs de la BCE (facilité de dépôt)	BCE	À chaque décision, prolongés jusqu'à la	Contrôles

Donnée	Source	Fréquence	Usage
		suivante	
VIX (volatilité implicite)	FRED	Quotidienne, moyenne mensuelle	Contrôle : aversion au risque
Indice des prix harmonisé France	Eurostat, via FRED	Mensuelle	Contrôle : inflation sur un an
Notations souveraines de la France	Communiqués des agences (Fitch, Moody's, S&P)	À chaque décision	Contrôle (extension E13)

Source : élaboration de l'auteur.

La situation mensuelle budgétaire (SMB) décrit l'exécution du budget de l'État, et seulement de l'État : la Sécurité sociale et les collectivités locales n'y figurent pas. On y trouve les dépenses du budget général par titre (personnel, fonctionnement, charge de la dette, investissement, intervention, opérations financières), les prélèvements sur recettes, les principales recettes et le solde. En revanche, ces fichiers ne donnent pas le détail par mission : il est impossible, par exemple, d'isoler les dépenses de défense.

Quatre caractéristiques de ces données comptent pour la suite :

- **Les taux de l'OCDE sont des moyennes mensuelles**, pas des valeurs de fin de mois. Or la variation d'une moyenne à la suivante est un peu corrélée d'un mois sur l'autre, par simple construction. Le CAC 40, lui, est pris au dernier jour du mois.
- **Le CAC 40 est un indice de prix**, qui ne compte pas les dividendes.
- **Les séries budgétaires sont la dernière version publiée.** Les chiffres de décembre, par exemple, sont d'abord provisoires puis révisés. Nous utilisons donc des valeurs un peu différentes de celles que le marché voyait en temps réel.
- **Le budget voté pour 2026 n'est pas dans les fichiers ouverts.** L'extension qui l'utilise (E4) s'arrête donc en février 2026.

2.2 Construction du jeu de données

Le jeu de données final compte **150 mois, de mars 2014 à août 2026**, dont 149 avec une cible (le dernier mois n'a pas encore de « mois suivant »). Une ligne correspond à la fin d'un mois t . Elle ne contient que ce qui était connu à cette date : c'est la règle qui guide toutes les étapes ci-dessous.

Formellement, pour chaque cible y , nous cherchons à prévoir la valeur du mois suivant à partir de l'information disponible à la fin du mois t :

$$y_{t+1} = f(M_t, B_{t-2}) + \varepsilon_{t+1}$$

où M regroupe les variables de marché et de contrôle connues à la fin du mois t (l'inflation étant celle du mois précédent), B les variables budgétaires du mois $t - 2$, f le modèle estimé et ε l'erreur de prévision.

2.2.1 Des cumuls aux flux mensuels.

La DGFIP publie des montants **cumulés depuis le 1er janvier** : le chiffre de mars additionne janvier, février et mars. Pour retrouver ce qui a été dépensé dans le mois, nous soustrayons le cumul du mois précédent. En janvier, le flux est simplement le cumul, puisque le compteur repart de zéro.

2.2.2 Neutraliser la saisonnalité.

L'État ne dépense pas au même rythme toute l'année. L'impôt sur les sociétés arrive à quelques échéances précises, et certaines dépenses se concentrent en fin d'année. Comparer un mois au mois précédent n'aurait donc pas de sens. Nous avons calculé deux transformations pour chaque ligne budgétaire :

- **La somme des 12 derniers mois** (en milliards d'euros). Elle donne le niveau annuel, sans effet de saison.

- **L'écart du cumul depuis janvier par rapport au même mois de l'année précédente, rapporté au montant des douze derniers mois** (en %). Une valeur de +1,2 en mai veut dire que, fin mai, l'État a dépensé l'équivalent de 1,2 % d'une année de plus que fin mai de l'année précédente. Comme on compare toujours le même mois, la saison s'annule.

Nous n'avons pas utilisé un simple taux de croissance du cumul. En début d'année, le cumul est presque nul, et le taux prend des valeurs absurdes : pour l'impôt sur les sociétés, il va de -449 % à +470 % en janvier et de -902 % à +1 789 % en février. Diviser par le montant des douze derniers mois règle ce problème.

Pour une ligne budgétaire i et un mois t , la variable utilisée dans les modèles s'écrit :

$$g_{i,t} = 100 \times \frac{C_{i,t} - C_{i,t-12}}{|S_{i,t}|} \quad \text{avec} \quad S_{i,t} = \sum_{k=0}^{11} F_{i,t-k}$$

où C est le cumul depuis janvier, F le flux mensuel et S la somme des douze derniers flux. Le numérateur compare le cumul au même mois de l'année précédente, ce qui retire la saisonnalité ; le dénominateur ne s'approche jamais de zéro, contrairement au cumul de début d'année.

Cette mesure a tout de même une limite. En janvier, elle compare un seul mois de dépenses ; en décembre, une année entière. Ses variations sont donc beaucoup plus fortes en fin d'année : pour les dépenses totales, l'écart-type passe de 0,7 en janvier à 4,4 en décembre. Une même valeur n'a donc pas tout à fait le même sens selon le mois.

Nous avons exclu les opérations financières. Ce sont des prises de participation ou des soutiens exceptionnels, très irréguliers, et non une dépense économique courante. Leur écart annuel atteignait -462 %.

2.2.3 Respecter le calendrier de publication.

La SMB d'un mois M paraît au début du mois $M+2$. Nous l'avons vérifié sur plusieurs communiqués du ministère : janvier 2023 publié le 2 mars 2023, décembre 2024 le 4 février 2025, juin 2026 le 4 août 2026, juillet 2026 le 2 septembre 2026. À la fin d'un mois t , un investisseur ne connaît donc que le budget du mois $t-2$. **Toutes les variables budgétaires sont décalées de deux mois.** Pour les années 2014 à 2022, nous n'avons pas retrouvé les dates exactes, car les archives ne sont plus en ligne : nous supposons le même calendrier.

Le même raisonnement vaut pour l'inflation. L'INSEE publie une estimation provisoire à la fin du mois, puis l'indice définitif vers le milieu du mois suivant (pour août 2026 : le 28 août, puis le 15 septembre). Nos données sont les valeurs définitives. **L'inflation est donc décalée d'un mois.**

Sans ces décalages, le modèle utiliserait des chiffres que personne ne connaissait encore au moment de la prévision. Ses performances seraient alors gonflées artificiellement. C'est le biais d'anticipation, bien connu pour les données macroéconomiques [18].

2.2.4 Vérification de la qualité des données.

Premier contrôle : à partir des fichiers mensuels, nous avons recalculé le solde de chaque année. Il correspond aux chiffres officiels, à 0,1 milliard près :

Tableau 2.2 – Soldes annuels reconstitués

Année	Solde reconstitué (Md€)
2014	-85,6
2020	-178,1
2023	-173,0
2024	-155,9

Source : calculs de l'auteur à partir des situations mensuelles budgétaires (DGFIP).

Second contrôle : un script de vérification (`tests/verifications.py`, 63 contrôles) s'assure automatiquement que chaque cible correspond bien au mois suivant, que chaque variable budgétaire vient du mois $t-2$, que l'inflation vient du mois $t-1$, et qu'aucun mois ne manque. Pour vérifier que ce script détecte bien les erreurs, nous l'avons relancé après avoir

modifié volontairement le décalage budgétaire (0 puis 1 mois au lieu de 2) : il signale chaque fois un échec. Le jeu de données n'a aucune valeur manquante, sauf la cible du dernier mois.

2.3 Variables cibles et stationnarité

Nous cherchons à prévoir trois indicateurs **pour le mois suivant (t+1)**. Nous les avons choisis avant d'explorer les données. Si nous avions retenu les cibles les plus corrélées aux dépenses, nous aurions trouvé un lien par construction, même sans lien réel.

Tableau 2.3 – Variables cibles

Cible	Définition	Unité	Moyenne	Écart-type
Variation du spread OAT–Bund (cible principale)	$\text{Spread}(t+1) - \text{spread}(t)$, où $\text{spread} = \text{OAT 10 ans} - \text{Bund 10 ans}$	points de base	0,12	5,27
Variation du taux OAT 10 ans	$\text{OAT}(t+1) - \text{OAT}(t)$	points de base	1,24	16,99
Rendement du CAC 40	$\text{CAC}(t+1) / \text{CAC}(t) - 1$	%	0,53	4,55

Source : calculs de l'auteur (OCDE via FRED, Yahoo Finance), mars 2014 – juillet 2026.

Le spread est notre cible principale. En retirant le taux allemand, on enlève ce qui bouge pour toute la zone euro, par exemple une décision de la BCE. Il reste le risque propre à la France, qui est celui que les finances publiques devraient influencer. Le taux OAT et le CAC 40 servent de points de comparaison : a priori, ils dépendent moins directement du budget de l'État.

Pourquoi prédire des variations plutôt que des niveaux.

Le test de Dickey-Fuller augmenté (ADF ; [19]) confirme que les trois cibles, en variations, sont stationnaires, alors que les niveaux ne le sont pas :

Tableau 2.4 – Test de stationnarité (Dickey-Fuller augmenté)

Série	p-value ADF	Stationnaire
Variation du spread, variation de l'OAT, rendement du CAC 40	< 0,001	oui
Niveau du spread	0,31	non
Niveau de l'OAT	0,94	non

Source : calculs de l'auteur.

Pourquoi ne pas prédire directement le niveau du spread ? Parce que le spread d'un mois ressemble beaucoup à celui du mois précédent. Un modèle qui recopie la dernière valeur obtient donc un R^2 très élevé, sans rien avoir appris. En prédisant la variation, on oblige le modèle à anticiper ce qui change vraiment. Nous verrons au chapitre 3 que ce piège n'est pas théorique : dans le panel européen (extension E16), nos modèles atteignent plus de 90 % de R^2 sur le niveau du spread, tout en faisant moins bien que la simple recopie du mois précédent.

Nous testons aussi une version plus simple dans les extensions : deviner seulement si le spread va monter ou baisser. Sur notre échantillon, il a monté dans 52 % des mois.

2.4 Variables explicatives

Nous n'avons pas choisi les variables une par une selon leurs corrélations. Nous avons construit trois jeux emboîtés, chacun contenant le précédent. Le test central du mémoire compare M0 et M1 : la seule différence entre les deux, ce sont les dépenses. Si M1 prévoit mieux, l'amélioration vient donc des dépenses, **en plus** de ce que les marchés savent déjà.

Tableau 2.5 – Jeux de variables emboîtés

Jeu	Contenu	Nombre de variables
M0 « marchés »	Variation du spread (t et t-1), niveau du spread, variation de l'OAT (t et t-1), rendement du CAC 40 (t et t-1), VIX et sa variation, inflation sur un an (du mois précédent), taux de la facilité de dépôt de la BCE	11
M1 « + dépenses »	M0 + écart annuel des dépenses totales, de personnel, de fonctionnement, de charge de la dette, d'investissement, d'intervention et des prélèvements sur recettes (décalés de 2 mois)	18
M2 « + budget complet »	M1 + recettes totales, recettes fiscales et variation du solde sur un an	21

Source : élaboration de l'auteur.

Les recettes et le solde sont à part, dans M2. Le titre du mémoire parle des **dépenses** : M1 répond à cette question précise, et M2 vérifie simplement si le reste du budget change la conclusion.

Deux pièges mis en évidence par l'analyse exploratoire.

Premier piège : les variables en niveau. Les dépenses sur 12 mois, en milliards d'euros, montent presque sans arrêt, avec l'inflation et la dette. Depuis 2022, les taux montent aussi. Or deux séries qui montent en même temps sont corrélées, même si elles n'ont rien à voir : la corrélation entre ces niveaux et la variation de l'OAT atteint 0,34, sans aucun sens économique. Ces niveaux ne sont pas stationnaires (p-values ADF de 0,23 à 1,00, supérieures à 0,7 pour 10 lignes sur 12). **Nos modèles utilisent donc les écarts annuels, pas les niveaux.** Ces écarts sont stationnaires ou presque (p-values ADF de 0,000 à 0,057).

Second piège : l'inflation. À première vue, les dépenses de personnel, de fonctionnement et la charge de la dette annoncent la variation de l'OAT (corrélations de Spearman de 0,17 à 0,23). Mais en 2022-2023, l'inflation semble avoir fait monter les deux en même temps : les taux, à cause de la BCE, et ces dépenses, à cause des salaires et de la dette indexée. Quand on retire l'effet de l'inflation et de la variation passée de l'OAT (les deux sont dans M0), ces corrélations tombent entre 0,09 et 0,15, sous le seuil de significativité (0,16). **Nous avons donc mis l'inflation dans M0**, pour ne pas attribuer aux dépenses un effet qui vient en réalité de l'inflation.

2.5 Modèles retenus

Nous traitons le problème comme une **régression** : le modèle prédit un nombre, qui donne à la fois le sens et l'ampleur du mouvement. C'est aussi le choix des travaux de référence [28, 14]. Nous comparons cinq approches, des plus simples aux plus flexibles :

Tableau 2.6 – Modèles comparés

Modèle	Rôle	Justification
--------	------	---------------

Moyenne historique	Référence minimale	Un modèle qui ne la bat pas n'a pas de pouvoir prédictif utile [36, 16]
Marche aléatoire (variation nulle)	Seconde référence	Prédit que le taux ou l'indice ne bougera pas ; référence classique pour les séries financières
Ridge (régression linéaire régularisée)	Approche économétrique	Représente la tradition linéaire ; la régularisation limite le surapprentissage avec 18 variables
Forêt aléatoire	Machine learning robuste	Capte les effets non linéaires, stable sur de petits échantillons [15, 34]
XGBoost	Machine learning de référence	Meilleur modèle chez Bouillot et al. [14] pour les spreads européens [17]

Source : élaboration de l'auteur.

Nous n'utilisons pas de deep learning. Avec environ 150 mois de données, un réseau de neurones apprendrait surtout le bruit. Les études qui l'emploient avec succès, comme Fischer et Krauss [24], travaillent sur des données quotidiennes de centaines d'actions, soit des centaines de milliers d'observations.

Hyperparamètres.

Nous n'avons pas cherché les meilleurs hyperparamètres sur la période de test. Quand on essaie beaucoup de réglages, on finit toujours par en trouver un qui « marche », mais par hasard. Nous avons donc retenu des valeurs usuelles :

- **Ridge** : paramètre de régularisation choisi automatiquement par validation croisée interne (leave-one-out) sur les seules données d'entraînement, parmi 40 valeurs entre 0,01 et 1 000 000. La grille initiale s'arrêtait à 1 000 ; lors d'une vérification du code, nous avons constaté que cette borne était atteinte la plupart des mois pour le CAC 40, et nous l'avons élargie (le R^2 de Ridge change d'au plus 1,2 point).
- **Forêt aléatoire** : 300 arbres, profondeur maximale 4, au moins 5 observations par feuille, 50 % des variables tirées à chaque division.

- **XGBoost** : 200 arbres, profondeur maximale 2, taux d'apprentissage 0,05, sous-échantillonnage de 80 % des observations et des variables, au moins 5 observations par feuille (`min_child_weight = 5`), pénalité L2 égale à 1.

La régression Ridge estime les coefficients en pénalisant leur taille, sur des variables centrées réduites :

$$\hat{\beta} = \arg \min_{\beta_0, \beta} \sum_s (y_{s+1} - \beta_0 - x_s^\top \beta)^2 + \alpha \sum_j \beta_j^2$$

Plus α est grand, plus les coefficients sont ramenés vers zéro. Quand α tend vers l'infini, la prévision se réduit à la constante, c'est-à-dire à la moyenne d'entraînement : choisir un α très élevé revient à dire que les variables n'apportent pas de signal.

Ces valeurs sont prudentes : des arbres peu profonds apprennent moins le bruit d'un petit échantillon. Nous devons toutefois être transparents sur un point. Contrairement aux extensions (section 2.7), ces réglages n'ont pas été datés dans le dépôt avant les premiers résultats : le code et les résultats ont été enregistrés ensemble. Pour vérifier que ce choix ne change pas les conclusions, nous l'avons remis en cause de deux façons : l'extension E10 règle XGBoost automatiquement par validation croisée temporelle, et un contrôle relance la forêt aléatoire et XGBoost avec plusieurs graines aléatoires (annexe).

2.6 Protocole d'évaluation

Nous évaluons les modèles comme s'ils avaient été utilisés en vrai, mois après mois : chaque prévision n'utilise que les données disponibles au moment où elle est faite.

2.6.1 Validation glissante.

Une validation croisée classique tire les mois au hasard. Le modèle pourrait alors apprendre sur 2024 pour prévoir 2021, ce qui n'a aucun sens pour une prévision. Nous utilisons donc une **validation glissante à fenêtre croissante** :

1. Fin janvier 2020, le modèle est entraîné sur les 70 mois précédents et prévoit la variation de février 2020.
2. Fin février 2020, il est réentraîné en ajoutant un mois, puis prévoit mars 2020.
3. L'opération est répétée chaque mois jusqu'à fin juillet 2026 (prévision d'août 2026).

La période de test compte **79 mois**. Dans tout le mémoire, elle est désignée par les mois où la prévision est faite (janvier 2020 à juillet 2026) ; les variations prévues vont de février 2020 à août 2026. Elle traverse des contextes très différents : le Covid-19, la hausse des taux de la BCE à partir de 2022, puis les tensions politiques et budgétaires françaises de 2024 à 2026.

2.6.2 Mesures de performance.

Tableau 2.7 – Mesures de performance

Mesure	Ce qu'elle mesure
RMSE (racine de l'erreur quadratique moyenne)	L'erreur typique, dans l'unité de la cible ; pénalise les grosses erreurs
MAE (erreur absolue moyenne)	L'erreur moyenne, moins sensible aux mois extrêmes
R ² hors échantillon	Le gain par rapport à la moyenne historique : positif si le modèle fait mieux, négatif sinon [16]
Taux de bonne direction	La part des mois où le sens du mouvement est correctement anticipé

Source : élaboration de l'auteur.

Notre mesure principale est le R² hors échantillon. Il compare les erreurs du modèle à celles de la moyenne historique :

$$R_{\text{OOS}}^2 = 1 - \frac{\sum_t (y_t - \hat{y}_t)^2}{\sum_t (y_t - \bar{y}_t)^2}$$

où y_t est la valeur observée, $\hat{y}_t$ la prévision du modèle et $\bar{y}_t$ la moyenne historique, calculée uniquement avec les mois antérieurs à t . Un R² positif veut dire que le modèle fait mieux que la moyenne ; un R² négatif, qu'il fait moins bien. Pour les taux, nous regardons aussi une seconde référence, la variation nulle, qui s'avère plus difficile à battre que la moyenne (chapitre 3).

2.6.3 Tests statistiques.

Un modèle peut faire un peu mieux qu'un autre par pur hasard. Pour le savoir, nous utilisons le **test de Diebold et Mariano** [20], avec la correction de Harvey, Leybourne et Newbold [29] pour les petits échantillons. Il nous dit si l'écart d'erreurs entre deux modèles est assez grand pour ne pas être dû au hasard. Nous l'appliquons à trois comparaisons :

- M1 contre M0 pour chaque modèle (test de l'hypothèse H1) ;
- chaque modèle contre la prévision « variation nulle » ;
- forêt aléatoire et XGBoost contre Ridge (hypothèse H3).

Pour deux prévisions concurrentes, dont les erreurs sur les T mois de test sont notées e_1 et e_2 , le test porte sur l'écart des erreurs au carré :

$$d_t = e_{1,t}^2 - e_{2,t}^2, \quad DM = \frac{\bar{d}}{\sqrt{\hat{\gamma}_0/T}}, \quad DM^* = DM \times \sqrt{\frac{T-1}{T}}$$

où le numérateur est la moyenne des écarts d et $\hat{\gamma}$ leur variance. DM^* est la statistique corrigée de Harvey, Leybourne et Newbold [29] pour un horizon d'un mois ; elle est comparée à une loi de Student à $T - 1$ degrés de liberté. Pour les horizons plus longs (extension E1), la variance tient compte de l'autocorrélation des écarts ($h - 1$ retards).

2.6.4 Importance des variables.

Pour savoir quelles dépenses le modèle utilise le plus (hypothèse H4), nous calculons les **valeurs SHAP** de XGBoost [32]. Elles indiquent combien chaque variable pèse, en moyenne, dans les prédictions. Deux précautions s'imposent. D'abord, elles sont calculées sur tout l'échantillon : elles décrivent ce que le modèle utilise, pas ce qui améliore la prévision. Ensuite, une part d'importance ne veut rien dire sans point de comparaison. Nous la comparons donc à la part obtenue par sept variables de pur bruit, tirées au hasard, placées au même endroit que les dépenses.

2.6.5 Contrôles de solidité.

Après les premiers résultats, nous avons ajouté cinq contrôles, décrits ici et rapportés au chapitre 3 :

- **Graine aléatoire** : la forêt aléatoire et XGBoost sont réestimés avec 5 et 10 graines différentes.
- **Contrôle positif (puissance)** : on ajoute à M0 une variable fictive construite pour avoir une corrélation ρ donnée avec la cible ($\rho = 0,1 ; 0,2 ; 0,3 ; 0,5$ et 1), avec 10 tirages par valeur (un seul pour $\rho = 1$, où le résultat ne dépend pas du tirage), pour mesurer ce que le dispositif est capable de détecter.
- **Contrôle négatif** : on remplace les sept dépenses par sept variables de pur bruit (20 tirages pour Ridge, 5 pour la forêt, 10 pour XGBoost), pour savoir si les dépenses font mieux que des variables sans information.
- **Décalage de publication** : les modèles principaux sont relancés avec un décalage budgétaire de 1 et de 3 mois au lieu de 2.
- **Importance par permutation hors échantillon** : sur la période de test, on mélange au hasard les valeurs d'un groupe de variables et on mesure la hausse de l'erreur, avec Ridge et XGBoost.

2.7 Extensions datées avant exécution et correction des tests multiples

Un résultat pourrait dépendre d'un choix particulier : l'horizon, le modèle, la période. Pour le vérifier, nous avons décliné le protocole principal en vingt extensions, dont dix-neuf ont pu être réalisées (E14 n'a pas pu l'être, faute de données quotidiennes). **Avant de lancer chaque extension, nous avons daté sa liste et son protocole dans le dépôt GitHub**, et nous rapportons tous les résultats, favorables ou non.

Cette précaution répond à un risque bien décrit par Bailey et al. [5] : à force d’essayer des configurations, on finit toujours par en trouver une qui semble marcher, par hasard.

Le pré-enregistrement s’est fait en plusieurs étapes, et nous préférons le dire clairement. E1 à E13 ont été fixées ensemble le 26 septembre 2026, après les résultats du modèle principal mais avant toute extension. E14 à E16 ont été ajoutées avant leur collecte de données. E17 à E20, en revanche, ont été ajoutées le 27 septembre **après** avoir vu les résultats d’E15 et E16 (pré-enregistrement à 13 h 03, résultats d’E15 et E16 à 12 h 57). E19 et E20 ont été fixées avant la collecte de leurs données. E17 et E18, elles, réutilisent les données du panel d’E15 et E16, déjà collectées : seul leur protocole a été daté avant leur exécution. E18 est donc présentée comme exploratoire, car son idée vient directement d’un résultat d’E15.

Tableau 2.8 – Extensions testées

#	Extension	Justification
E1	Horizons de 3, 6 et 12 mois	Les dépenses agissent lentement sur la dette
E2	Classification hausse ou baisse	Deviner le sens est plus facile que l’ampleur
E3	Volatilité (ampleur du mouvement)	L’incertitude budgétaire peut agiter les marchés
E4	Surprise budgétaire : exécution par rapport au budget voté	Le marché réagit à l’information nouvelle [35]
E5	Effet selon le régime de taux	La sensibilité aux finances publiques varie dans le temps [1]
E6	Moins de variables, composantes principales	Réduire le surapprentissage
E7	Prévisions tempérées vers la moyenne	Campbell et Thompson [16]
E8	Combinaison de prévisions	Robustesse des moyennes de modèles
E9	Elastic Net	Sélection automatique des variables
E10	XGBoost réglé par validation croisée temporelle emboîtée	Vérifier que le choix des hyperparamètres n’est pas en cause
E11	Fenêtre glissante de 60 mois	S’adapter au changement de régime de 2022
E12	Évaluation par période (2020-2021, 2022-2026, marchés calmes ou agités)	Un apport peut être limité aux périodes de tension
E13	Notations souveraines de la France	Contrôle du risque perçu par les agences
E14	Étude d’événement autour des	Le marché intègre-t-il

#	Extension	Justification
	dates de publication (non réalisée : taux quotidiens introuvables)	l'information budgétaire le jour même ?
E15	Panel européen trimestriel (5 pays, Eurostat)	Plus d'observations, inclusion de la crise de la dette 2010-2012
E16	Panel européen mensuel avec une base large de variables	Répliquer le cadre de Bouillot et al. [14] en le comparant à la marche aléatoire
E17	Panel annuel (valeurs de décembre)	Les finances publiques agiraient à basse fréquence
E18	Régime de crise (exploratoire)	Les marchés ne regarderaient le budget qu'en période de tension
E19	Actions des secteurs liés à la dépense publique (BTP, défense)	Canal des revenus des entreprises
E20	Incertitude de politique économique (indice européen de [6])	Contrôler l'incertitude politique ; l'indice français n'étant pas disponible, nous avons déclaré ce changement avant l'exécution

Source : élaboration de l'auteur ; plan daté dans docs/plan_extensions.md.

Pour les horizons de plus d'un mois (E1), une difficulté apparaît : à la date de la prévision, les dernières cibles ne sont pas encore connues. Le modèle n'est donc entraîné que sur des cibles déjà observées, et le test de Diebold-Mariano tient compte du chevauchement des périodes.

Correction des tests multiples.

Avec plus de 150 comparaisons, environ une sur vingt paraîtrait significative au seuil de 5 %, par pur hasard. Nous corrigeons donc toutes les p-values « avec dépenses contre sans dépenses » par la **procédure de Benjamini et Hochberg [10]**, avec un taux de fausses découvertes de 10 %. Nous ne considérons comme significatifs que les résultats qui résistent à cette correction. Elle porte sur 168 comparaisons (dont E20a, qui compare avec et sans l'indice d'incertitude) ; les ventilations par sous-période (E12, E18) en sont exclues car elles ne sont pas des tests indépendants. La même correction est appliquée séparément aux 18 tests de H1 du modèle principal. Pour la correction, nous utilisons la p-value unilatérale (« avec dépenses meilleur que sans ») ; les tableaux descriptifs donnent la p-value bilatérale.

La procédure est la suivante. Les m p-values sont classées par ordre croissant, de la plus petite, $p(1)$, à la plus grande, $p(m)$. On cherche le plus grand rang k tel que :

$$p_{(k)} \leq \frac{k}{m} q, \quad q = 0,10$$

et l'on déclare significatives les k premières comparaisons. De façon équivalente, chaque comparaison reçoit une p -value corrigée, qui est celle rapportée dans nos tableaux ; une comparaison est significative si sa p -value corrigée est inférieure à q . Avec $m = 168$, une p -value brute doit être au plus de $0,10/168$, soit environ $0,0006$, pour être retenue quand elle est la plus petite et que toutes les autres sont élevées.

2.8 Considérations éthiques

Données. Toutes les données utilisées sont publiques et en accès libre : situations budgétaires de l'État (data.economie.gouv.fr), séries de marché et macroéconomiques (FRED, BCE, Eurostat), indices boursiers. Elles ne contiennent aucune donnée personnelle, et sont utilisées dans le respect des conditions de réutilisation de chaque fournisseur (licence ouverte pour les données publiques françaises). Les sources sont citées, et la liste des fichiers bruts est figée dans le dépôt (manifeste des données).

Transparence et résultats négatifs. Le code, les données traitées et les résultats sont conservés dans un dépôt GitHub (accessible sur demande), et l'ensemble peut être relancé avec un seul script. Le plan des extensions a été daté avant leur exécution. Nous rapportons tous les résultats, y compris négatifs, et corrigeons pour les tests multiples. Ne publier que les résultats favorables donnerait une image fausse de ce que les données permettent ; c'est un problème connu en finance empirique [5].

Usage des résultats. Ce travail n'est pas un conseil en investissement. Un modèle qui paraît prédire les marchés peut conduire à des décisions coûteuses s'il est mal évalué ; c'est pourquoi nous insistons sur la comparaison à des références simples.

Outils d'intelligence artificielle. Des outils d'IA générative ont été utilisés pour l'aide à la programmation, la relecture du code et l'aide à la rédaction. Leur usage est décrit dans la déclaration prévue par le guide de l'ECE. Les choix de recherche relèvent de l'auteur, qui a relu l'ensemble du texte et en assume la responsabilité.

Chapitre 3 – Résultats

Ce chapitre présente les résultats, sans les interpréter : l'interprétation vient au chapitre 4. Nous décrivons d'abord les données (3.1), puis les performances des modèles principaux (3.2). Nous vérifions ensuite la solidité de ces résultats (3.3) et l'importance des variables (3.4). Les sections 3.5 et 3.6 résument les dix-neuf extensions réalisées ; leur détail est en annexe. La section 3.7 fait le point sur les hypothèses.

Tous les résultats portent sur la période de test de janvier 2020 à juillet 2026 (79 mois), en validation glissante. Un R^2 hors échantillon positif signifie que le modèle fait mieux que la moyenne historique ; un R^2 négatif, qu'il fait moins bien.

3.1 Statistiques descriptives

Les trois cibles, en variations, sont stationnaires (p-value ADF inférieure à 0,001). Elles sont très dispersées par rapport à leur moyenne, et peu corrélées d'un mois sur l'autre.

Tableau 3.1 – Statistiques des variables cibles (mars 2014 – juillet 2026, 149 mois)

Cible	Moyenne	Écart-type	Minimum	Maximum	Autocorrélation d'ordre 1
Variation du spread OAT–Bund (pb)	0,12	5,27	-18,1	20,5	0,14
Variation du taux OAT (pb)	1,24	16,99	-54,0	72,0	0,23
Rendement du CAC 40 (%)	0,53	4,55	-17,2	20,1	-0,09

Source : calculs de l'auteur (OCDE via FRED, Yahoo Finance).

Le niveau du spread varie entre 26,4 points de base (septembre 2016) et 83,6 points de base (janvier 2025). Les plus fortes variations mensuelles du spread sont observées en mars 2020 (+20,5 pb), mai 2017 (-18,1 pb), février 2017 (+16,3 pb), juin 2024 (+15,5 pb) et novembre 2016 (+15,3 pb).

Les corrélations de Spearman entre les dépenses (mois t-2) et les cibles (mois t+1) sont faibles. Pour le spread, seule la ligne investissement atteint le seuil de 5 % (-0,16). Pour la variation de l'OAT, trois lignes le dépassent : personnel (0,23), charge de la dette (0,21) et

fonctionnement (0,17). Une fois l'inflation et la variation passée de la cible contrôlées (corrélation partielle ; ces deux variables sont dans M0), elles descendent à 0,15 (personnel), 0,09 (fonctionnement) et 0,10 (charge de la dette), sous le seuil (p de 0,08 à 0,26). Pour le spread, l'investissement passe à -0,15 (p = 0,06). Pour le CAC 40, aucune corrélation n'est significative.




Figure 3.1 – Distribution des trois cibles

Source : calculs de l'auteur.

3.2 Modèles principaux

Aucun modèle ne bat la moyenne historique, pour aucune des trois cibles. Le meilleur R^2 hors échantillon est celui de Ridge M0 sur le CAC 40 : -1,3 %. Pour les deux taux, la prévision « variation nulle » fait mieux que la moyenne (+1,7 % et +2,4 %).

Tableau 3.2 – R^2 hors échantillon par rapport à la moyenne historique (%), janvier 2020 – juillet 2026

Modèle	Jeu de variables	Δ spread	Δ OAT	CAC 40
Moyenne historique	—	0,0	0,0	0,0
Variation nulle	—	+1,7	+2,4	-0,2
Ridge	M0 marchés	-14,9	-11,3	-1,3
Ridge	M1 + dépenses	-14,7	-11,3	-3,5
Ridge	M2 + budget complet	-27,8	-9,0	-1,8
Forêt aléatoire	M0 marchés	-6,8	-6,9	-9,6
Forêt aléatoire	M1 + dépenses	-8,4	-6,9	-10,8
Forêt aléatoire	M2 + budget complet	-10,5	-5,9	-11,2
XGBoost	M0 marchés	-35,4	-30,2	-31,7
XGBoost	M1 + dépenses	-30,1	-30,4	-27,8
XGBoost	M2 + budget complet	-28,4	-33,1	-26,7

Source : calculs de l'auteur (*results/tables/models_metrics.csv*). Graine aléatoire 42 pour la forêt et XGBoost.

Le taux de bonne direction varie entre 42 % et 59 % selon les modèles. La moyenne historique obtient 53 % (spread), 57 % (OAT) et 61 % (CAC 40).

Le tableau 3.3 donne les tests de Diebold-Mariano (DM) pour les deux questions centrales : les dépenses améliorent-elles la prévision (H1), et le machine learning fait-il mieux que Ridge (H3) ?

Tableau 3.3 – Tests de Diebold-Mariano (p-values bilatérales)

Comparaison	Δ spread	Δ OAT	CAC 40
Ridge : M1 contre M0	0,97	0,99	0,37
Forêt aléatoire : M1 contre M0	0,58	0,99	0,77
XGBoost : M1 contre M0	0,61	0,98	0,63
Forêt aléatoire contre Ridge (M1)	0,35	0,41	0,18
XGBoost contre Ridge (M1)	0,22	0,06	0,03 (XGBoost moins bon)

Source : calculs de l'auteur (*results/tables/models_dm_tests.csv*).

Aucune comparaison M1 contre M0 n'est significative : les p-values vont de 0,37 à 0,99. Entre modèles, la seule différence significative au seuil de 5 % concerne le CAC 40 : XGBoost y fait moins bien que Ridge ($p = 0,03$). Face à la prévision « variation nulle », les modèles avec dépenses (M1) sont significativement moins bons dans deux cas sur six pour les taux (Ridge et XGBoost sur le spread, $p = 0,04$ et $0,03$) ; les autres écarts ne sont pas significatifs.

Nous avons aussi appliqué la correction de Benjamini et Hochberg aux 18 tests de H1 (M1 et M2 contre M0, trois modèles, trois cibles). La plus petite p-value corrigée vaut 0,81.




Figure 3.2 – RMSE relatif à la moyenne historique

Source : calculs de l'auteur.

3.3 Solidité des résultats

Quatre contrôles complètent le tableau 3.2. Ils ont été ajoutés après les premiers résultats, lors d'une vérification du code.

Graine aléatoire. La forêt aléatoire et XGBoost dépendent d'un tirage au hasard. Nous les avons réestimés avec 5 graines (forêt) et 10 graines (XGBoost). Le R^2 de XGBoost varie d'environ 9 points selon la graine (par exemple de -39,8 % à -30,8 % pour le spread, jeu M0), celui de la forêt d'environ 3 points. Avec toutes les graines, le R^2 reste négatif, et aucun test DM M1 contre M0 n'est significatif (plus petite p-value : 0,13).

Puissance du test (contrôle positif). Pour savoir si notre dispositif peut détecter un vrai signal, nous avons ajouté à M0 une variable fictive corrélée à la cible (corrélation ρ), avec Ridge et 10 tirages par valeur de ρ , un seul pour $\rho = 1$ (tableau 3.4).

Tableau 3.4 – Contrôle positif : part des tirages où le signal est retrouvé (Ridge, 10 tirages par valeur de ρ , 1 pour $\rho = 1$)

Corrélation ρ du signal fictif	Bat la moyenne historique	Test DM significatif (5 %) avec gain
0,1	0 %	0 %
0,2	0 à 20 %	0 à 30 %
0,3	20 à 30 %	0 à 50 %
0,5	80 à 100 %	30 à 80 %
1,0	100 %	100 %

Source : calculs de l'auteur (results/tables/diag_04/positif.csv). Plages sur les trois cibles.

Un signal de corrélation 0,3 avec la cible n'est retrouvé que dans une minorité de tirages. Un signal de corrélation 0,5 bat presque toujours la moyenne, mais le test DM ne le détecte pas toujours.

Contrôle négatif (variables de bruit). Nous avons remplacé les sept dépenses par sept variables de pur bruit, puis comparé le gain par rapport à M0. Avec Ridge (20 tirages), 90 à 95 % des tirages de bruit font au moins aussi bien que les vraies dépenses. Avec la forêt aléatoire (5 tirages), c'est 80 à 100 %. Avec XGBoost (10 tirages), c'est 50 à 60 %.

Décalage de publication. La date de publication des situations budgétaires n'est vérifiée que pour 2023-2026. Nous avons donc relancé les modèles principaux avec un décalage de 1 mois et de 3 mois, au lieu de 2. Aucun R^2 ne devient positif (meilleur R^2 : -0,7 % avec 1 mois, -2,7 % avec 3 mois, jeu M1). Aucun test M1 contre M0 n'est significatif après correction (plus petite p-value corrigée : 0,51).

Source : results/tables/diag_04/bruit_.csv, graines_*.csv et results/tables/robustesse_lag.csv. Le détail des tirages est en annexe.*

3.4 Importance des variables

Dans un XGBoost estimé sur tout l'échantillon (jeu M1), les sept variables de dépenses représentent **31 à 37 %** de l'importance SHAP totale. Parmi les sept dépenses, les dépenses d'intervention arrivent en tête pour le spread et l'OAT, l'investissement pour le CAC 40.

Nous avons aussi remplacé les sept dépenses par sept variables de pur bruit, tirées au hasard (10 tirages). Ces variables obtiennent en moyenne **34 à 38 %** de l'importance SHAP.

Tableau 3.5 – Part de l'importance SHAP des sept variables ajoutées à M0 (%)

Variables ajoutées	Δ spread	Δ OAT	CAC 40
Sept dépenses publiques	32,8	36,8	30,6
Sept variables de bruit (moyenne de 10 tirages)	38,1	34,2	37,1
Sept variables de bruit (minimum – maximum)	34,3 – 43,5	26,5 – 41,6	28,6 – 46,8

Source : calculs de l'auteur (results/tables/models_shap_importance.csv, results/tables/diag_04/shap_bruit.csv).

Pour l'OAT et le CAC 40, la part des dépenses se situe dans l'intervalle obtenu avec du bruit. Pour le spread, elle est inférieure au plus petit des dix tirages de bruit.

Une seconde mesure, calculée hors échantillon, a été ajoutée après les premiers résultats : l'importance par permutation, calculée avec Ridge et XGBoost sur deux versions de M1, qui servent de repères : l'une avec sept variables de bruit, l'autre avec le signal fictif ($\rho = 0,5$). On mélange au hasard les valeurs d'un groupe de variables sur la période de test, puis on mesure la hausse de l'erreur. Quand on mélange les sept dépenses dans la version avec bruit, l'erreur n'augmente pas : le RMSE baisse légèrement, de 0,1 % à 2,5 % selon la cible et le modèle. Dans la version avec signal, l'effet des dépenses va de -3,9 % à +0,1 %. Quand on mélange le signal fictif du contrôle positif ($\rho = 0,5$), le RMSE augmente de 7,6 % à 18,8 %.

Source : calculs de l'auteur (*results/tables/models_permutation_oos.csv*).




Figure 3.3 – Importance SHAP des variables

Source : calculs de l'auteur.

3.5 Extensions sur les données françaises

Les extensions E1 à E13 changent un seul élément à la fois : l'horizon, la forme de la cible, les variables, le modèle ou la fenêtre d'entraînement. Elles ont été décrites avant leur exécution (chapitre 2). Le tableau 3.6 donne, pour chaque extension, le meilleur R^2 hors

échantillon obtenu sans les dépenses, puis avec les dépenses. E12, qui découpe la période de test en sous-périodes, n'y figure pas. Le détail par modèle est en annexe B.

Tableau 3.6 – Meilleur R² hors échantillon sans / avec dépenses, par extension (%)

Extension	Δ spread	Δ OAT	CAC 40
Modèle principal (h = 1)	-6,8 / -8,4	-6,9 / -6,9	-1,3 / -3,5
E1 Horizon 3 mois	+2,3 / -8,6	-2,7 / -7,6	-9,1 / -14,7
E1 Horizon 6 mois	-12,1 / -20,6	-27,5 / -38,0	-30,3 / -39,5
E1 Horizon 12 mois	-93,9 / -97,3	-29,8 / -28,2	+11,8 / -16,5
E2 Hausse / baisse (score de Brier)	-2,4 / +0,5	+2,5 / +5,8	-3,7 / -6,8
E3 Volatilité	-4,3 / -7,7	+3,3 / +4,2	+9,6 / +6,4
E4 Surprise budgétaire	-6,0 / -11,1	-7,1 / -7,2	-1,4 / -0,4
E5 Interactions avec le régime de taux	-14,0 / -29,5	-12,2 / -19,0	-4,8 / -13,7
E6 Variables réduites / ACP	-5,3 / -4,7	-5,7 / -4,6	-3,6 / -2,6
E7 Prévisions tempérées	-1,5 / -2,8	0,0 / +0,1	-0,6 / -1,6
E8 Combinaison des modèles	-3,5 / -4,3	-1,8 / -2,0	-3,9 / -4,2
E9 Elastic Net	-2,7 / -4,9	-6,7 / -7,6	-0,3 / -3,8
E10 XGBoost réglé	-4,4 / -6,2	-4,8 / -5,4	-6,2 / -3,0
E11 Fenêtre glissante de 60 mois	-6,2 / -8,9	-8,7 / -10,4	-4,0 / -7,6
E13 Notations souveraines	-5,7 / -8,6	-5,2 / -6,8	0,0 / -10,8

Source : calculs de l'auteur (*results/tables/ext_synthese.csv*). Test de janvier 2020 à juillet 2026 (E4 : jusqu'à février 2026). E2 : amélioration du score de Brier par rapport à la fréquence historique. Pour E2, E3 et E7, la référence est différente de celle du tableau 3.2.

Sur 45 cases, le modèle sans dépenses fait mieux que le modèle avec dépenses dans 34 cas.

Les cases positives sans dépenses sont : la volatilité (E3) pour l'OAT et le CAC 40, la classification de l'OAT (E2), le spread à 3 mois (+2,3 %) et le CAC 40 à 12 mois (+11,8 %, sur 68 prévisions qui se chevauchent). Avec les dépenses, quatre cases sont positives et meilleures que sans : E2 pour le spread (+0,5 contre -2,4) et pour l'OAT (+5,8 contre +2,5), E3 pour l'OAT (+4,2 contre +3,3) et E7 pour l'OAT (+0,1 contre 0,0). Aucune de ces différences n'est significative (voir ci-dessous).

Pour les actions sectorielles (E19, rendement en excès du CAC 40, horizons 1 et 3 mois), le meilleur R² est de +1,4 % sans dépenses et -0,7 % avec pour le BTP, de 0,0 % et -1,7 % pour

la défense. Avec l'indice d'incertitude politique (E20), aucune cible n'a de R^2 positif, avec ou sans dépenses.

Correction pour tests multiples. Au total, 168 comparaisons « avec contre sans dépenses » entrent dans la correction de Benjamini et Hochberg (taux de fausses découvertes de 10 %). Aucune n'est significative après correction ; la plus petite p-value corrigée vaut 0,999. Avant correction, 6 p-values sont inférieures à 0,05, alors que 8,4 sont attendues par le seul hasard. Dans ces 6 cas, le modèle avec dépenses est moins mauvais que le modèle sans, mais son R^2 reste négatif.




Figure 3.4 – Synthèse des extensions

Source : calculs de l'auteur.

3.6 Panel européen et marche aléatoire (E15 à E18)

Les extensions E15 à E18 utilisent un panel de cinq pays (France, Italie, Espagne, Portugal, Belgique), avec des finances publiques harmonisées par Eurostat. La cible est le spread de chaque pays face au Bund.

E15 – panel trimestriel. Sur 330 prévisions (2010T1 à 2026T2), Ridge obtient +13,9 % sans dépenses et +15,5 % avec dépenses ($p = 0,37$). Un diagnostic complémentaire, non prévu au départ, donne l'autocorrélation d'ordre 1 de la cible : 0,32 en moyenne trimestrielle, contre 0,07 pour le spread de fin de trimestre. Sur 2010-2014, ajouter les dépenses améliore le R^2 de Ridge de 4,1 points en moyenne trimestrielle et de 3,4 points en fin de trimestre ; après 2015, il le dégrade de 12,8 et 11,2 points. Ces écarts par sous-période ne sont pas testés. Avec le spread de fin de trimestre, les deux R^2 deviennent négatifs : -4,1 % sans dépenses et -2,9 % avec.

E16 – réplification élargie de Bouillot et al. [14]. Le panel mensuel compte 150 variables, dont 18 de finances publiques, et 874 prévisions. Sur le **niveau** du spread, le R^2 par rapport à la moyenne atteint 92 à 97 % avec les finances publiques. Mais tous les modèles font moins bien que la marche aléatoire, qui prévoit le spread du mois dernier (tableau 3.7). Sur la **variation** du spread, le R^2 est négatif pour tous les modèles. Les finances publiques n'améliorent aucune prévision (p de 0,08 à 0,81). Sur la France seule, de janvier 2020 à février 2025, la marche aléatoire a une erreur (RMSE) de 5,1 points de base sur le niveau du spread mensuel moyen.

Tableau 3.7 – E16 : niveau du spread, comparaison à la marche aléatoire (avec finances publiques)

Modèle	R^2 vs moyenne (%)	Gain vs marche aléatoire (%)	RMSE (pb)
Marche aléatoire	—	0	18,4
XGBoost	97,0	-30,9	21,1
Forêt aléatoire	94,5	-141,6	28,6
Ridge	92,4	-232,3	33,6

Source : calculs de l'auteur (*results/tables/extensions/E16.csv*). Test à partir de janvier 2012, 5 pays.

E17 – panel annuel. Sur 75 prévisions annuelles, tous les modèles font moins bien que la moyenne (R^2 de -20 % à -338 %) et que la marche aléatoire. La forêt aléatoire avec dépenses est moins mauvaise que sans (-19,8 % contre -45,4 %, $p = 0,04$ avant correction).

E18 – régime de crise (exploratoire). L'ajout d'interactions entre dépenses et période de tension (spread supérieur à 200 pb) dégrade la prévision pour Ridge (le R^2 passe de -3,3 % à -19,7 %) et pour XGBoost (de -20,2 % à -26,2 %). La forêt aléatoire passe de -10,4 % à -4,9 % ($p = 0,20$).

3.7 Synthèse : état des hypothèses

Tableau 3.8 – État des hypothèses

Hypothèse	Résultat	Éléments
H1 : les dépenses améliorent la prévision d'au moins un indicateur	Non validée	DM M1 contre M0 : p de 0,37 à 0,99 (tableau 3.3) ; p corrigée $\geq 0,81$ sur les 18 tests de H1 ; 0 comparaison significative sur 168 dans les extensions (3.5) ; même résultat avec un décalage de 1 ou 3 mois (3.3)
H2 : l'apport décroît du spread à l'OAT, puis au CAC 40	Non testable	Aucun apport à classer
H3 : forêt aléatoire et XGBoost font mieux que les modèles linéaires	Non validée	Forêt $\approx$ Ridge (p de 0,18 à 0,41) ; XGBoost moins bon que Ridge sur le CAC 40 ($p = 0,03$)
H4 : charge de la dette et dépenses d'intervention sont les plus prédictives	Non soutenue	Part SHAP des dépenses (31 à 37 %) comparable à celle de variables de bruit (34 à 38 %) (tableau 3.5) ; permuter les dépenses n'augmente pas l'erreur hors échantillon

Source : sections 3.2 à 3.5.

Chapitre 4 – Discussion

4.1 Réponse à la problématique

Nous voulions savoir si les données ouvertes de dépenses publiques permettent de prévoir des indicateurs des marchés financiers avec du machine learning.

Pour la France et à un mois, la réponse est non : nous ne trouvons **aucune preuve** que les dépenses de l'État améliorent la prévision du spread OAT–Bund, du taux OAT ou du CAC 40. Ce résultat vaut pour les trois modèles, pour un décalage de publication d'un à trois mois, et pour les dix-neuf extensions une fois les tests multiples corrigés.

Il faut bien lire ce que cela veut dire. Nous ne montrons pas que les dépenses n'ont aucun lien avec les marchés. Avec 79 mois de test, un lien faible ou moyen pourrait nous échapper (section 4.3). Et nous ne regardons que l'exécution mensuelle du budget de l'État, pas les annonces budgétaires ni l'ensemble des administrations publiques. C'est pourquoi nous écrivons « pas de preuve » et non « les dépenses ne permettent pas de prédire » : la première formule décrit ce que nos tests montrent, la seconde affirmerait une impossibilité que nos données ne peuvent pas démontrer.

Le second constat va au-delà des dépenses : **aucun modèle ne bat la moyenne historique**, même sans elles. Pour les taux, la prévision « pas de variation le mois prochain » fait mieux que la moyenne et mieux que tous nos modèles, même si l'écart n'est significatif que dans quelques cas. À un mois, ces marchés restent très difficiles à prévoir avec les variables dont nous disposons.

4.2 Pourquoi les dépenses n'aident pas : trois pistes

Voici trois explications possibles. Elles peuvent se cumuler, et aucune n'est démontrée par nos tests.

L'information est peut-être déjà connue.

Le budget de l'État est voté en décembre pour l'année suivante. Les marchés peuvent donc intégrer le plan de dépenses avant même le début de l'année, et la situation mensuelle, publiée deux mois plus tard, ne ferait que confirmer ce qui était attendu. Un prix réagit à ce qui est nouveau, pas à ce qui est déjà prévu [22]. Ramey [35] va dans le même sens : pour les dépenses publiques, c'est le moment de l'annonce qui compte, plus que celui de la dépense. Attinasi et al. [4] observent la même chose pendant la crise de 2007-2009 : ce sont les annonces de plans de sauvetage bancaire qui ont pesé sur les spreads, pas les montants engagés. Notre extension E4 pointe aussi dans cette direction, puisque l'écart entre l'exécution et le budget voté, qui mesure une forme de surprise, n'améliore pas la prévision.

Pour vérifier cette idée, il faudrait observer le spread le jour même de chaque publication, avec une étude d'événement. Nous n'avons pas pu la faire, faute de taux quotidiens accessibles (sections 4.7 et 4.8).

Ce qui fait bouger le spread n'est pas budgétaire.

Les plus fortes variations mensuelles du spread tombent en mars 2020 (+20,5 pb), en février et mai 2017 (+16,3 et -18,1 pb) et en juin 2024 (+15,5 pb). Elles coïncident avec le début de la crise du Covid-19, la campagne présidentielle de 2017 et l'annonce de la dissolution de l'Assemblée nationale le 9 juin 2024. Ce dernier cas touche bien les finances publiques, mais par un canal politique : on craint qu'une nouvelle majorité ne tienne pas la trajectoire budgétaire. C'est une anticipation, et elle n'apparaît dans aucune ligne de dépense déjà exécutée.

Une information lente et tardive pour une cible rapide.

Les dépenses de l'État reflètent des décisions prises à l'avance et évoluent plus lentement que les marchés, qui réagissent en quelques jours. Nous essayons de prévoir un mouvement rapide avec une information lente, qui arrive en plus avec deux mois de retard.

La littérature européenne trouve pourtant un lien entre finances publiques et spreads [11, 1]. Il n'y a pas de contradiction : ces études **expliquent le niveau** des spreads, en panel et souvent en période de crise, alors que nous essayons de **prévoir la variation** du mois suivant, hors échantillon. La France n'a de plus pas connu de crise de la dette sur notre période, contrairement à l'Italie ou à l'Espagne en 2011-2012, et Afonso et al. [1] montrent que les marchés sanctionnent surtout les finances publiques quand la tension monte. Notre panel trimestriel va un peu dans ce sens : entre 2010 et 2014, ajouter les dépenses améliore le R^2 de Ridge de 4 points, alors qu'il le dégrade de près de 13 points après 2015 (section 3.6). Mais ces écarts ne sont pas testés, et le modèle qui introduit des interactions avec les périodes de tension (E18) ne les confirme pas.

4.3 Ce que le résultat négatif veut dire, et ce qu'il ne veut pas dire

Un résultat négatif n'a de valeur que si l'on sait ce que le test aurait pu détecter. Nous avons trois éléments pour en juger.

La puissance du test.

Le contrôle positif (section 3.3) ajoute à M_0 une variable fictive corrélée à la cible. Avec une corrélation de 0,5, le modèle bat la moyenne historique dans 80 à 100 % des tirages ; avec 0,3, dans 20 à 30 % seulement. Notre dispositif repère donc un signal fort mais manquerait souvent un signal moyen. Nos tests écartent un fort pouvoir prédictif des dépenses, pas un effet faible. La cause principale est la taille de l'échantillon : les séries budgétaires ouvertes commencent en 2013, ce qui ne laisse que 79 mois de test, et le choix de commencer le test en 2020 pour garder assez de mois d'entraînement y contribue.

Le contrôle négatif.

Si l'on remplace les sept dépenses par sept variables tirées au hasard, 90 à 95 % des tirages de bruit font au moins aussi bien que les vraies dépenses avec Ridge. Les petits écarts entre

M1 et M0 ne sont donc pas propres aux dépenses : n'importe quelles variables ajoutées donnent des écarts du même ordre. Cela change aussi la lecture de l'importance des variables. Les dépenses pèsent 31 à 37 % de l'importance SHAP, ce qui paraît beaucoup, mais du bruit en obtient 34 à 38 %. Une part d'importance élevée dans un modèle d'arbres ne prouve donc pas qu'une variable est utile.

Le choix de la référence.

Pour les taux, la prévision « pas de variation » bat la moyenne historique : la moyenne n'est pas la référence la plus exigeante. Le panel trimestriel (E15) montre un autre piège. Un R^2 de +15 % venait du fait que la cible était une moyenne sur le trimestre, en partie prévisible par construction [37] ; avec le spread de fin de trimestre, il devient négatif. Un bon score ne suffit donc pas : il faut le comparer à une référence simple et à du bruit, et vérifier que la cible ne contient pas de régularité mécanique.

4.4 Retour sur les modèles

Les arbres ne font pas mieux que Ridge (H3).

On pouvait espérer que le machine learning trouve des relations non linéaires. C'est le contraire : XGBoost est le moins bon des trois modèles et la forêt aléatoire ne fait pas mieux que Ridge. Deux éléments peuvent l'expliquer.

D'abord le rapport entre signal et bruit. Avec 70 à 148 mois d'entraînement et des cibles très bruitées, un modèle flexible peut s'ajuster à des coïncidences de l'échantillon d'apprentissage, qui ne se reproduisent pas ensuite. L'instabilité de XGBoost, dont le R^2 varie d'environ 9 points selon la seule graine aléatoire, est compatible avec cette idée.

Ensuite le comportement de Ridge. Quand il ne trouve pas de signal, il augmente sa pénalité et rapproche sa prévision de la moyenne. Pour le CAC 40, la pénalité dépasse 10 000 dans 27 % des mois (M0) à 44 % (M1), et Ridge devient presque la moyenne historique, avec un R^2

proche de zéro (-1,3 %). Le « meilleur » modèle est donc celui qui renonce le plus à prévoir. Cela rejoint une observation de Bouillot et al. [14] : pour la Belgique et l'Espagne, une régression pénalisée (LASSO, Elastic Net) a un RMSE plus faible que XGBoost. Le machine learning n'est pas inutile pour autant, mais il lui faut plus d'observations ou un signal plus fort que ce que nos données offrent à un mois.

L'importance des variables ne dit rien ici (H4).

Les valeurs SHAP semblaient d'abord soutenir H4, avec les dépenses d'intervention en tête parmi les dépenses. Mais des variables de pur bruit obtiennent la même part d'importance, et mélanger les dépenses sur la période de test n'augmente pas l'erreur. Un modèle d'arbres utilise toutes les variables qu'on lui donne, même inutiles : il faut comparer leur importance à celle du bruit avant d'en tirer une conclusion.

Ce qui reste prévisible.

Quelques extensions battent la moyenne, mais **sans les dépenses** : la volatilité (E3 : +9,6 % pour le CAC 40, +3,3 % pour l'OAT), le sens de variation de l'OAT (E2 : score de Brier +2,5 %) et le CAC 40 à 12 mois (E1 : +11,8 %). Ce dernier résultat est fragile, car il repose sur 68 prévisions qui se chevauchent. Que la volatilité soit en partie prévisible n'a rien d'étonnant : les périodes agitées se suivent [21]. Dans aucun de ces cas les dépenses n'apportent de gain significatif. Ce qui se prévoit un peu vient des marchés eux-mêmes.

4.5 Comparaison avec la littérature

Bouillot, Candelon et Kool.

L'étude la plus proche de la nôtre annonce un R^2 de 0,81 à 0,99 selon les pays (0,86 pour la France) et une erreur de 7,3 points de base pour la France sur 2020-2025 [14]. Nos résultats semblent contraires aux leurs, mais ils ne mesurent pas la même chose. Ces auteurs prévoient le **niveau** du spread. Or le spread d'un mois est très proche de celui du mois précédent, et une simple recopie du dernier spread donne déjà un R^2 très élevé face à la moyenne. Leur propre

analyse montre d'ailleurs que le spread passé domine les prévisions dans tous les pays. Dans la version de leur document de travail que nous avons consultée, les treize méthodes sont comparées entre elles et à la moyenne, mais pas à la marche aléatoire. Le résumé d'une version plus récente indique que l'AR(1) et la marche aléatoire ont des erreurs plus faibles que les modèles de machine learning dans chaque pays, quand ceux-ci sont réestimés à chaque date.

Nos résultats vont dans le même sens. Dans notre panel européen (E16), nous retrouvons un R^2 de 92 à 97 % sur le niveau du spread, mais tous nos modèles font moins bien que la marche aléatoire (pour XGBoost, une erreur de 21,1 points de base contre 18,4). Sur la France et la même période qu'eux (janvier 2020 à février 2025), la marche aléatoire a une erreur de 5,1 points de base dans nos données, contre 7,3 pour leur XGBoost. Cette comparaison est à lire avec prudence : nos séries sont des moyennes mensuelles et leur définition du spread peut être différente. Un R^2 sur le niveau ne suffit donc pas à juger une prévision, et la comparaison à la marche aléatoire est indispensable. Autre point commun : chez eux aussi, les finances publiques pèsent très peu, avec une seule variable de finances publiques parmi les cinq plus importantes de chacun des dix pays, soit 50 au total. Ce que nous apportons en plus, c'est d'isoler les dépenses en comparant le même modèle avec et sans elles. Sur le machine learning, en revanche, nous ne retrouvons pas leur résultat : XGBoost est le moins bon de nos modèles (H3).

Welch et Goyal.

Welch et Goyal [36] montrent que la plupart des variables proposées pour prévoir la bourse américaine ne battent pas la moyenne historique hors échantillon. Nos résultats sur le CAC 40 vont dans le même sens, et la même difficulté apparaît pour le spread et le taux OAT à un mois.

Les autres études européennes.

Afonso et al. [1] et Bernoth et al. [11] trouvent un lien entre finances publiques et spreads, mais sur des périodes qui incluent la crise de la dette et pour expliquer le niveau des spreads (section 4.2). Belly et al. [9] trouvent que le machine learning suit mieux les spreads que les modèles économétriques sur 2004-2019 ; leur question porte sur la supériorité d'une famille de modèles, la nôtre sur l'apport d'un bloc de variables. Garlanda-Longueville [25] observe, en données quotidiennes, un effet des allocutions du président de la République pendant la crise du Covid sur le CAC 40 et sur le spread. Ce résultat est compatible avec le nôtre : il suggère que ce sont les annonces, vues au jour le jour, qui font bouger les marchés plutôt que l'exécution mensuelle publiée deux mois plus tard.

4.6 Implications

Pour la recherche. Un résultat de prévision doit toujours être comparé à une référence simple (la moyenne historique et, pour les taux, la variation nulle) et à du bruit. Sans ces repères, un R^2 élevé sur un niveau ou une forte part d'importance SHAP peuvent faire croire à un pouvoir prédictif qui n'existe pas. Publier aussi les résultats négatifs, avec des contrôles de puissance, évite que la littérature ne retienne que les configurations qui ont l'air de marcher.

Pour les investisseurs. Nos résultats ne donnent aucune raison d'utiliser l'exécution mensuelle du budget de l'État pour prévoir le spread, le taux OAT ou le CAC 40 à un mois. Ils ne disent pas que les finances publiques sont sans importance pour les marchés : l'information utile se trouve peut-être plutôt dans les annonces et les anticipations.

Pour les producteurs de données ouvertes. Un calendrier de publication archivé et la conservation des versions successives des chiffres permettraient de travailler avec l'information réellement disponible à chaque date.

4.7 Limites

- **Données révisées.** Nous utilisons la dernière version publiée des situations budgétaires, pas les chiffres connus à chaque date (ceux de décembre sont d'abord provisoires).
- **Date de publication.** Le décalage de deux mois est vérifié sur 2023-2026 seulement ; pour 2014-2022, c'est une hypothèse. Les résultats ne changent pas avec un décalage d'un ou de trois mois (section 3.3).
- **Périmètre.** Les données couvrent le budget de l'État, pas la Sécurité sociale ni les collectivités, et ne sont pas ventilées par mission.
- **Cibles de taux en moyennes mensuelles.** Le spread et le taux OAT sont des moyennes du mois (OCDE), alors que le CAC 40 est pris en fin de mois. Les variations de moyennes sont un peu autocorrélées par construction.
- **Variables budgétaires inégales dans l'année.** L'écart-type de l'écart cumulé est en médiane 6,3 fois plus grand en décembre qu'en janvier.
- **Petit échantillon.** Avec 70 à 148 mois d'entraînement et 79 mois de test, seul un effet fort pouvait être détecté. Les écarts de quelques points de R^2 entre deux modèles ne sont pas interprétables.
- **Hyperparamètres.** Ils ont été fixés à des valeurs usuelles, sans réglage sur la période de test, mais le code et les résultats des modèles principaux ont été enregistrés ensemble : nous ne pouvons pas prouver qu'ils ont été choisis avant de voir les résultats. Seules les extensions ont un plan daté avant leur exécution. Les chiffres de XGBoost et de la forêt aléatoire dépendent aussi des versions des bibliothèques logicielles, pas les conclusions.

- **Extensions ajoutées en cours de route.** E17 à E20 ont été ajoutées après avoir vu les résultats d'E15 et E16, et E18 est exploratoire. E14 (étude d'événement) n'a pas pu être réalisée.
- **Panel européen.** Pour E16, 25 des 68 séries de l'OCDE ne sont plus mises à jour depuis fin 2022 ou début 2024 : environ 23 % des valeurs de la fin de la période de test sont donc complétées. Pour E19, les prix des actions n'incluent pas les dividendes.
- **Pas d'étude d'événement.** L'explication « l'information est déjà connue » (section 4.2) reste donc une hypothèse.

4.8 Recherches futures

- **Étude d'événement.** Avec des taux quotidiens et les dates exactes de publication des situations budgétaires, on pourrait mesurer la réaction du spread le jour même. C'est le test direct de l'explication « l'information est déjà connue ».
- **Les annonces plutôt que l'exécution.** Le projet de loi de finances, les lois de finances rectificatives et les programmes de stabilité sont de l'information nouvelle pour les marchés. On pourrait les coder comme des surprises, par exemple par l'écart entre le déficit annoncé et les prévisions des économistes.
- **Données en temps réel.** Conserver chaque version publiée des situations budgétaires.
- **Plus d'observations.** Un panel de pays plus long, incluant la crise de 2010-2012, avec des cibles de fin de période plutôt que des moyennes.
- **Ventilation sectorielle.** Les données de la commande publique permettraient de relier la dépense aux entreprises bénéficiaires et de mieux tester le canal des actions sectorielles (E19).

Conclusion générale

Ce mémoire posait une question simple : les données ouvertes de dépenses publiques permettent-elles de prévoir les marchés financiers ? Pour y répondre, nous avons construit un jeu de données mensuel à partir des situations budgétaires de l'État français, en respectant leur délai réel de publication, et nous avons comparé des modèles avec et sans dépenses pour trois indicateurs : le spread OAT–Bund, le taux OAT et le CAC 40.

Principaux résultats

La réponse est négative, pour l'instant. Nous ne trouvons aucune preuve que les dépenses de l'État améliorent la prévision à un mois. Ce résultat tient pour les trois méthodes, pour les dix-neuf extensions réalisées, avec un décalage de publication d'un à trois mois, et après correction pour les tests multiples (168 comparaisons d'extensions et 18 tests du modèle principal). Aucune des hypothèses de départ n'est validée : les dépenses n'apportent pas de gain significatif (H1) ; il n'y a donc pas d'apport à classer entre les indicateurs (H2, non testable) ; le machine learning ne fait pas mieux qu'une régression linéaire (H3) ; et aucune ligne de dépense ne se détache (H4, non soutenue).

Plus largement, dans le modèle principal, aucun modèle ne bat la moyenne historique, et pour les taux, la prévision « pas de variation » fait mieux que tous les modèles. À un mois, ces marchés restent très difficiles à prévoir.

Apports

Nous répondons d'abord à une question précise, avec une méthode qui isole l'effet des dépenses, sur un pays peu étudié. Nos contrôles montrent ensuite ce que le dispositif aurait pu détecter (un effet fort, pas forcément un effet faible), et que du pur bruit obtient autant d'importance que les dépenses dans un modèle d'arbres. Enfin, un R^2 de plus de 90 % sur le niveau du spread, comme dans la littérature récente, peut aller avec une prévision moins

bonne que la simple reconduction du dernier spread : la comparaison à une référence naïve est indispensable.

Limites

Les principales limites sont la taille de l'échantillon (79 mois de test), qui ne permet de détecter qu'un effet fort ; l'utilisation de données budgétaires révisées plutôt que des chiffres connus à chaque date ; l'absence de crise de la dette française sur la période ; et l'absence d'étude d'événement, qui aurait permis de tester directement si les marchés réagissent à la publication des chiffres.

Perspectives

Deux pistes nous semblent les plus prometteuses. La première est une étude d'événement à fréquence quotidienne, autour des dates de publication des situations budgétaires. La seconde consiste à étudier les annonces budgétaires (projet de loi de finances, programmes de stabilité) plutôt que l'exécution, car c'est au moment de l'annonce que l'information devient nouvelle pour les marchés.

Ce résultat invite à la prudence. Avec des finances publiques françaises qui inquiètent, il est tentant de chercher dans chaque publication budgétaire un signal pour les marchés. Nos résultats suggèrent que ce signal, s'il existe dans l'exécution mensuelle du budget, est trop faible pour être exploité.

Références

- [1] Afonso, A., Arghyrou, M. G., & Kantonikas, A. (2015). *The determinants of sovereign bond yield spreads in the EMU*. ECB Working Paper No. 1781.
- [2] Afonso, A., & Sousa, R. M. (2011). What are the effects of fiscal policy on asset markets? *Economic Modelling*, 28(4), 1871–1890.
<https://doi.org/10.1016/j.econmod.2011.03.018>
- [3] Ardagna, S. (2009). Financial markets' behavior around episodes of large changes in the fiscal stance. *European Economic Review*, 53(1), 37–55.
<https://doi.org/10.1016/j.euroecorev.2008.07.003>
- [4] Attinasi, M.-G., Checherita, C., & Nickel, C. (2009). *What explains the surge in euro area sovereign spreads during the financial crisis of 2007-09?* ECB Working Paper No. 1131. <https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp1131.pdf>
- [5] Bailey, D. H., Borwein, J. M., López de Prado, M., & Zhu, Q. J. (2014). Pseudo-mathematics and financial charlatanism: The effects of backtest overfitting on out-of-sample performance. *Notices of the American Mathematical Society*, 61(5), 458–471.
<https://doi.org/10.1090/noti1105>
- [6] Baker, S. R., Bloom, N., & Davis, S. J. (2016). Measuring economic policy uncertainty. *The Quarterly Journal of Economics*, 131(4), 1593–1636.
<https://doi.org/10.1093/qje/qjw024>
- [7] Barbier-Gauchard, A., & Sofianos, E. (2025). *Forecasting public debt in the euro area using machine learning: Decision tools for financial markets*. *Computational Economics*. <https://doi.org/10.1007/s10614-025-11106-9>
- [8] Barro, R. J. (1974). Are government bonds net wealth? *Journal of Political Economy*, 82(6), 1095–1117. <https://doi.org/10.1086/260266>
- [9] Belly, G., Boeckelmann, L., Caicedo Graciano, C. M., Di Iorio, A., Istrefi, K., Siakoulis, V., & Stalla-Bourdillon, A. (2023). *Forecasting sovereign risk in the Euro area via machine learning*. *Journal of Forecasting*, 42(3), 657–684.
<https://doi.org/10.1002/for.2938>
- [10] Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B*, 57(1), 289–300. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>
- [11] Bernoth, K., von Hagen, J., & Schuknecht, L. (2012). Sovereign risk premiums in the European government bond market. *Journal of International Money and Finance*, 31(5), 975–995. <https://doi.org/10.1016/j.jimonfin.2011.12.006>
- [12] Bianchi, D., Büchner, M., & Tamoni, A. (2021). *Bond risk premiums with machine learning*. *The Review of Financial Studies*, 34(2), 1046–1089.
<https://doi.org/10.1093/rfs/hhaa062>
- [13] Blanchard, O., & Perotti, R. (2002). An empirical characterization of the dynamic effects of changes in government spending and taxes on output. *The Quarterly Journal of Economics*, 117(4), 1329–1368. <https://doi.org/10.1162/003355302320935043>
- [14] Bouillot, R., Candelon, B., & Kool, C. (2025). *Forecasting European sovereign spreads using machine learning*. LIDAM Discussion Paper LFIN 2025/04, UCLouvain.

- [15] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- [16] Campbell, J. Y., & Thompson, S. B. (2008). Predicting excess stock returns out of sample: Can anything beat the historical average? *The Review of Financial Studies*, 21(4), 1509–1531. <https://doi.org/10.1093/rfs/hhm055>
- [17] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [18] Croushore, D. (2011). Frontiers of real-time data analysis. *Journal of Economic Literature*, 49(1), 72–100. <https://doi.org/10.1257/jel.49.1.72>
- [19] Dickey, D. A., & Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association*, 74(366), 427–431. <https://doi.org/10.2307/2286348>
- [20] Diebold, F. X., & Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3), 253–263.
<https://doi.org/10.1080/07350015.1995.10524599>
- [21] Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4), 987–1007.
<https://doi.org/10.2307/1912773>
- [22] Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, 25(2), 383–417. <https://doi.org/10.1111/j.1540-6261.1970.tb00518.x>
- [23] Favero, C. A. (2013). *Modelling and forecasting government bond spreads in the euro area: A GVAR model*. *Journal of Econometrics*, 177(2), 343–356.
<https://doi.org/10.1016/j.jeconom.2013.04.004>
- [24] Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654–669. <https://doi.org/10.1016/j.ejor.2017.11.054>
- [25] Garlanda-Longueville, L. (2023). *Fiscalité bancaire, politique monétaire et annonces budgétaires : trois essais en économie bancaire et financière internationale* [Thèse de doctorat, Université Paris Nanterre, dir. V. Mignon].
- [26] Giannone, D., Reichlin, L., & Small, D. (2008). Nowcasting: The real-time informational content of macroeconomic data. *Journal of Monetary Economics*, 55(4), 665–676. <https://doi.org/10.1016/j.jmoneco.2008.05.010>
- [27] Goulet Coulombe, P., Leroux, M., Stevanovic, D., & Surprenant, S. (2022). How is machine learning useful for macroeconomic forecasting? *Journal of Applied Econometrics*, 37(5), 920–964. <https://doi.org/10.1002/jae.2910>
- [28] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, 33(5), 2223–2273. <https://doi.org/10.1093/rfs/hhaa009>
- [29] Harvey, D., Leybourne, S., & Newbold, P. (1997). Testing the equality of prediction mean squared errors. *International Journal of Forecasting*, 13(2), 281–291.
[https://doi.org/10.1016/S0169-2070\(96\)00719-4](https://doi.org/10.1016/S0169-2070(96)00719-4)

- [30] Janssen, M., Charalabidis, Y., & Zuiderwijk, A. (2012). Benefits, adoption barriers and myths of open data and open government. *Information Systems Management*, 29(4), 258–268. <https://doi.org/10.1080/10580530.2012.716740>
- [31] Laubach, T. (2009). New evidence on the interest rate effects of budget deficits and debt. *Journal of the European Economic Association*, 7(4), 858–885. <https://doi.org/10.1162/jeea.2009.7.4.858>
- [32] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30. <https://papers.nips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- [33] McCracken, M. W., & Ng, S. (2016). FRED-MD: A monthly database for macroeconomic research. *Journal of Business & Economic Statistics*, 34(4), 574–589. <https://doi.org/10.1080/07350015.2015.1086655>
- [34] Medeiros, M. C., Vasconcelos, G. F. R., Veiga, Á., & Zilberman, E. (2021). Forecasting inflation in a data-rich environment: The benefits of machine learning methods. *Journal of Business & Economic Statistics*, 39(1), 98–119. <https://doi.org/10.1080/07350015.2019.1637745>
- [35] Ramey, V. A. (2011). Identifying government spending shocks: It’s all in the timing. *The Quarterly Journal of Economics*, 126(1), 1–50. <https://doi.org/10.1093/qje/qjq008>
- [36] Welch, I., & Goyal, A. (2008). A comprehensive look at the empirical performance of equity premium prediction. *The Review of Financial Studies*, 21(4), 1455–1508. <https://doi.org/10.1093/rfs/hhm014>
- [37] Working, H. (1960). Note on the correlation of first differences of averages in a random chain. *Econometrica*, 28(4), 916–918. <https://doi.org/10.2307/1907574>

Sources en ligne

Ministère de l’Économie. [Situations mensuelles budgétaires de l’État, séries longues depuis 2013](#). data.economie.gouv.fr.

DGFiP. [La situation mensuelle de l’État](#). economie.gouv.fr.

[Dépôt du projet](#), GitHub (code, données, plan daté des extensions `docs/plan_extensions.md`).

[FRED](#), Federal Reserve Bank of St. Louis (taux OAT et Bund, séries OCDE, VIX).

[Portail de données de la BCE](#) (taux directeurs).

[Eurostat](#) (IPCH, finances publiques trimestrielles).

[Yahoo Finance](#) (CAC 40 et actions sectorielles).

[Economic Policy Uncertainty](#) (indice européen d’incertitude).

Annexes

Annexe A – Variables des modèles principaux

Tableau A.1 – Variables des jeux emboîtés M0, M1 et M2

Jeu	Variable	Définition
M0	d_spread, d_spread_l1	Variation du spread OAT–Bund (mois t et t-1), en points de base
M0	spread_bp	Niveau du spread OAT–Bund (mois t)
M0	d_oat, d_oat_l1	Variation du taux OAT 10 ans (mois t et t-1)
M0	cac_ret, cac_ret_l1	Rendement du CAC 40 (mois t et t-1)
M0	vix, d_vix	Niveau et variation du VIX (aversion au risque)
M0	inflation_yoy	Inflation IPCH France sur un an (décalée d'un mois)
M0	ecb_dfr	Taux de la facilité de dépôt de la BCE
M1	b_dep_totales, personnel, fonctionnement, charge_dette, investissement, intervention (_ytd_gap)	Écart du cumul depuis janvier par rapport à l'année précédente, en % du montant des douze derniers mois (décalé de 2 mois)
M1	b_psr_total_ytd_gap	Prélèvements sur recettes, même transformation
M2	b_rec_totales, b_rec_fiscales (_ytd_gap)	Recettes totales et fiscales, même transformation
M2	b_solde_ytd_diff_yoy	Solde d'exécution cumulé, écart sur un an

Source : *src/04_models.py*. $M1 = M0 + dépenses$; $M2 = M1 + recettes et solde$.

Annexe B – Détail des extensions E1 à E20

Chaque ligne compare le même modèle sans et avec les dépenses (ou les finances publiques).

« p brute » : test de Diebold-Mariano unilatéral « avec meilleur que sans » ; « p corrigée » : correction de Benjamini-Hochberg sur les 168 comparaisons retenues (E12 et ventilations exclues : « — »). E16 : R^2 par rapport à la moyenne.

Tableau B.1 – Résultats des 210 comparaisons

Extension	Cible	Comparaison	n	R^2 sans (%)	R^2 avec (%)	p brute	p corrigée (BH)
E1 horizon	Δ spread	Ridge h=3 : M1 contre M0	77	-61,8	-199,1	0,999	0,999
E1 horizon	Δ spread	forêt h=3 : M1 contre M0	77	2,3	-8,6	0,945	0,999
E1 horizon	Δ spread	XGBoost	77	-26,2	-35,4	0,714	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		h=3 : M1 contre M0					
E1 horizon	Δ OAT	Ridge h=3 : M1 contre M0	77	-51,7	-92,8	0,983	0,999
E1 horizon	Δ OAT	forêt h=3 : M1 contre M0	77	-2,7	-7,6	0,661	0,999
E1 horizon	Δ OAT	XGBoost h=3 : M1 contre M0	77	-14,9	-19,6	0,593	0,999
E1 horizon	CAC 40	Ridge h=3 : M1 contre M0	77	-38,5	-140,6	0,982	0,999
E1 horizon	CAC 40	forêt h=3 : M1 contre M0	77	-9,1	-14,7	0,908	0,999
E1 horizon	CAC 40	XGBoost h=3 : M1 contre M0	77	-49,1	-45,5	0,356	0,999
E1 horizon	Δ spread	Ridge h=6 : M1 contre M0	74	-107,1	-193,0	0,993	0,999
E1 horizon	Δ spread	forêt h=6 : M1 contre M0	74	-12,1	-20,6	0,945	0,999
E1 horizon	Δ spread	XGBoost h=6 : M1 contre M0	74	-36,9	-30,5	0,271	0,999
E1 horizon	Δ OAT	Ridge h=6 : M1 contre M0	74	-157,5	-265,6	0,968	0,999
E1 horizon	Δ OAT	forêt h=6 : M1 contre M0	74	-27,5	-38,0	0,835	0,999
E1 horizon	Δ OAT	XGBoost h=6 : M1 contre M0	74	-46,9	-61,5	0,770	0,999
E1 horizon	CAC 40	Ridge h=6 : M1 contre M0	74	-115,5	-257,3	0,969	0,999
E1 horizon	CAC 40	forêt h=6 : M1 contre M0	74	-30,3	-39,5	0,872	0,999
E1 horizon	CAC 40	XGBoost h=6 : M1 contre M0	74	-89,7	-53,2	0,027	0,999
E1 horizon	Δ spread	Ridge h=12 : M1 contre M0	68	-638,2	-524,5	0,365	0,999
E1 horizon	Δ spread	forêt h=12 : M1 contre M0	68	-93,9	-97,3	0,667	0,999
E1 horizon	Δ spread	XGBoost h=12 : M1 contre M0	68	-195,8	-152,6	0,013	0,999
E1 horizon	Δ OAT	Ridge h=12 : M1 contre M0	68	-686,4	-869,4	0,849	0,999
E1 horizon	Δ OAT	forêt h=12 :	68	-29,8	-28,2	0,438	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		M1 contre M0					
E1 horizon	Δ OAT	XGBoost h=12 : M1 contre M0	68	-70,0	-53,2	0,140	0,999
E1 horizon	CAC 40	Ridge h=12 : M1 contre M0	68	-515,9	-463,7	0,284	0,999
E1 horizon	CAC 40	forêt h=12 : M1 contre M0	68	2,7	-16,5	0,895	0,999
E1 horizon	CAC 40	XGBoost h=12 : M1 contre M0	68	11,8	-26,8	0,787	0,999
E2 classification	Δ spread	logistique : M1 contre M0 (perte de Brier)	79	-24,4	-25,6	0,549	0,999
E2 classification	Δ spread	forêt : M1 contre M0 (perte de Brier)	79	-2,4	0,5	0,257	0,999
E2 classification	Δ spread	XGBoost : M1 contre M0 (perte de Brier)	79	-12,9	-7,5	0,236	0,999
E2 classification	Δ OAT	logistique : M1 contre M0 (perte de Brier)	79	-16,1	-30,1	0,980	0,999
E2 classification	Δ OAT	forêt : M1 contre M0 (perte de Brier)	79	2,5	5,8	0,186	0,999
E2 classification	Δ OAT	XGBoost : M1 contre M0 (perte de Brier)	79	-4,7	-2,3	0,323	0,999
E2 classification	CAC 40	logistique : M1 contre M0 (perte de Brier)	79	-3,7	-17,1	0,939	0,999
E2 classification	CAC 40	forêt : M1 contre M0 (perte de Brier)	79	-6,1	-6,8	0,600	0,999
E2 classification	CAC 40	XGBoost : M1 contre M0 (perte de Brier)	79	-24,1	-20,6	0,237	0,999
E3 volatilité	Δ spread	Ridge : M1 contre M0	79	-4,4	-7,7	0,937	0,999
E3 volatilité	Δ spread	forêt : M1 contre M0	79	-17,9	-14,0	0,157	0,999
E3 volatilité	Δ spread	XGBoost : M1 contre M0	79	-51,4	-37,6	0,118	0,999
E3 volatilité	Δ OAT	Ridge : M1 contre M0	79	3,3	2,0	0,710	0,999
E3 volatilité	Δ OAT	forêt : M1	79	2,8	4,2	0,346	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		contre M0					
E3 volatilité	Δ OAT	XGBoost : M1 contre M0	79	-7,0	-6,5	0,466	0,999
E3 volatilité	CAC 40	Ridge : M1 contre M0	79	-1,3	-3,4	0,783	0,999
E3 volatilité	CAC 40	forêt : M1 contre M0	79	9,6	6,4	0,876	0,999
E3 volatilité	CAC 40	XGBoost : M1 contre M0	79	3,8	0,4	0,677	0,999
E4 surprise	Δ spread	Ridge : M0 + surprise contre M0	74	-13,5	-16,4	0,791	0,999
E4 surprise	Δ spread	Ridge : M1 + surprise contre M0	74	-13,5	-16,2	0,650	0,999
E4 surprise	Δ spread	forêt : M0 + surprise contre M0	74	-6,0	-11,1	0,928	0,999
E4 surprise	Δ spread	forêt : M1 + surprise contre M0	74	-6,0	-12,4	0,901	0,999
E4 surprise	Δ spread	XGBoost : M0 + surprise contre M0	74	-34,0	-51,0	0,942	0,999
E4 surprise	Δ spread	XGBoost : M1 + surprise contre M0	74	-34,0	-39,3	0,662	0,999
E4 surprise	Δ OAT	Ridge : M0 + surprise contre M0	74	-11,9	-14,2	0,943	0,999
E4 surprise	Δ OAT	Ridge : M1 + surprise contre M0	74	-11,9	-12,0	0,502	0,999
E4 surprise	Δ OAT	forêt : M0 + surprise contre M0	74	-7,1	-7,2	0,541	0,999
E4 surprise	Δ OAT	forêt : M1 + surprise contre M0	74	-7,1	-8,5	0,634	0,999
E4 surprise	Δ OAT	XGBoost : M0 + surprise contre M0	74	-29,6	-30,7	0,584	0,999
E4 surprise	Δ OAT	XGBoost : M1 + surprise contre M0	74	-29,6	-35,2	0,759	0,999
E4 surprise	CAC 40	Ridge : M0 + surprise contre M0	74	-1,4	-0,4	0,208	0,999
E4 surprise	CAC 40	Ridge : M1 + surprise contre M0	74	-1,4	-2,1	0,656	0,999
E4 surprise	CAC 40	forêt : M0 + surprise contre M0	74	-9,5	-11,6	0,925	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
E4 surprise	CAC 40	forêt : M1 + surprise contre M0	74	-9,5	-10,2	0,583	0,999
E4 surprise	CAC 40	XGBoost : M0 + surprise contre M0	74	-31,6	-35,6	0,871	0,999
E4 surprise	CAC 40	XGBoost : M1 + surprise contre M0	74	-31,6	-30,6	0,446	0,999
E5 régime	Δ spread	Ridge : M1 + interactions régime contre M0 + régime	79	-14,0	-29,5	0,831	0,999
E5 régime	Δ OAT	Ridge : M1 + interactions régime contre M0 + régime	79	-12,2	-19,0	0,914	0,999
E5 régime	CAC 40	Ridge : M1 + interactions régime contre M0 + régime	79	-4,8	-13,7	0,956	0,999
E6 réduit	Δ spread	Ridge : réduit + 2 dépenses contre réduit	79	-5,3	-4,7	0,322	0,999
E6 réduit	Δ spread	Ridge : réduit + 2 composantes principales des dépenses contre réduit	79	-5,3	-5,2	0,462	0,999
E6 réduit	Δ spread	forêt : réduit + 2 dépenses contre réduit	79	-11,2	-13,5	0,747	0,999
E6 réduit	Δ spread	forêt : réduit + 2 composantes principales des dépenses contre réduit	79	-11,2	-14,9	0,874	0,999
E6 réduit	Δ spread	XGBoost : réduit + 2 dépenses contre réduit	79	-37,4	-41,9	0,650	0,999
E6 réduit	Δ spread	XGBoost : réduit + 2	79	-37,4	-40,3	0,618	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		composantes principales des dépenses contre réduit					
E6 réduit	Δ OAT	Ridge : réduit + 2 dépenses contre réduit	79	-6,1	-4,6	0,321	0,999
E6 réduit	Δ OAT	Ridge : réduit + 2 composantes principales des dépenses contre réduit	79	-6,1	-6,3	0,539	0,999
E6 réduit	Δ OAT	forêt : réduit + 2 dépenses contre réduit	79	-5,7	-8,9	0,836	0,999
E6 réduit	Δ OAT	forêt : réduit + 2 composantes principales des dépenses contre réduit	79	-5,7	-10,0	0,876	0,999
E6 réduit	Δ OAT	XGBoost : réduit + 2 dépenses contre réduit	79	-24,6	-34,5	0,924	0,999
E6 réduit	Δ OAT	XGBoost : réduit + 2 composantes principales des dépenses contre réduit	79	-24,6	-32,8	0,805	0,999
E6 réduit	CAC 40	Ridge : réduit + 2 dépenses contre réduit	79	-3,6	-2,6	0,161	0,999
E6 réduit	CAC 40	Ridge : réduit + 2 composantes principales des dépenses contre réduit	79	-3,6	-2,6	0,224	0,999
E6 réduit	CAC 40	forêt : réduit + 2 dépenses contre	79	-8,9	-8,2	0,418	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		réduit					
E6 réduit	CAC 40	forêt : réduit + 2 composantes principales des dépenses contre réduit	79	-8,9	-6,6	0,195	0,999
E6 réduit	CAC 40	XGBoost : réduit + 2 dépenses contre réduit	79	-34,7	-31,5	0,351	0,999
E6 réduit	CAC 40	XGBoost : réduit + 2 composantes principales des dépenses contre réduit	79	-34,7	-30,9	0,271	0,999
E7 tempérée	Δ spread	Ridge 50/50 avec la moyenne : M1 contre M0	79	-2,6	-4,0	0,716	0,999
E7 tempérée	Δ spread	forêt 50/50 avec la moyenne : M1 contre M0	79	-1,5	-2,8	0,825	0,999
E7 tempérée	Δ spread	XGBoost 50/50 avec la moyenne : M1 contre M0	79	-10,5	-9,6	0,425	0,999
E7 tempérée	Δ OAT	Ridge 50/50 avec la moyenne : M1 contre M0	79	-2,5	-2,7	0,539	0,999
E7 tempérée	Δ OAT	forêt 50/50 avec la moyenne : M1 contre M0	79	-0,0	0,1	0,481	0,999
E7 tempérée	Δ OAT	XGBoost 50/50 avec la moyenne : M1 contre M0	79	-5,7	-6,1	0,557	0,999
E7 tempérée	CAC 40	Ridge 50/50 avec la moyenne : M1 contre M0	79	-0,6	-1,7	0,820	0,999
E7 tempérée	CAC 40	forêt 50/50 avec la moyenne :	79	-3,7	-4,4	0,625	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		M1 contre M0					
E7 tempérée	CAC 40	XGBoost 50/50 avec la moyenne : M1 contre M0	79	-10,4	-9,1	0,362	0,999
E8 combinaison	Δ spread	moyenne Ridge/RF/XGB : M1 contre M0	79	-13,4	-13,0	0,468	0,999
E8 combinaison	Δ spread	combinaison tempérée 50/50 : M1 contre M0	79	-3,5	-4,3	0,638	0,999
E8 combinaison	Δ OAT	moyenne Ridge/RF/XGB : M1 contre M0	79	-12,3	-12,7	0,540	0,999
E8 combinaison	Δ OAT	combinaison tempérée 50/50 : M1 contre M0	79	-1,8	-2,0	0,556	0,999
E8 combinaison	CAC 40	moyenne Ridge/RF/XGB : M1 contre M0	79	-10,2	-10,6	0,540	0,999
E8 combinaison	CAC 40	combinaison tempérée 50/50 : M1 contre M0	79	-3,9	-4,2	0,556	0,999
E9 Elastic Net	Δ spread	Elastic Net : M1 contre M0	79	-2,7	-4,9	0,815	0,999
E9 Elastic Net	Δ OAT	Elastic Net : M1 contre M0	79	-6,7	-7,6	0,631	0,999
E9 Elastic Net	CAC 40	Elastic Net : M1 contre M0	79	-0,3	-3,8	0,922	0,999
E10 XGB réglé	Δ spread	XGBoost réglé : M1 contre M0	79	-4,4	-6,2	0,844	0,999
E10 XGB réglé	Δ OAT	XGBoost réglé : M1 contre M0	79	-4,8	-5,4	0,549	0,999
E10 XGB réglé	CAC 40	XGBoost réglé : M1 contre M0	79	-6,2	-3,0	0,175	0,999
E11 fenêtre 60 mois	Δ spread	Ridge : M1 contre M0	79	-11,8	-14,3	0,639	0,999
E11 fenêtre 60 mois	Δ spread	forêt : M1 contre M0	79	-6,2	-8,9	0,755	0,999
E11 fenêtre 60 mois	Δ spread	XGBoost : M1 contre M0	79	-25,9	-25,6	0,490	0,999
E11 fenêtre 60 mois	Δ OAT	Ridge : M1 contre M0	79	-8,7	-17,6	0,931	0,999
E11 fenêtre	Δ OAT	forêt : M1	79	-9,5	-10,4	0,609	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
60 mois		contre M0					
E11 fenêtre 60 mois	Δ OAT	XGBoost : M1 contre M0	79	-43,4	-36,7	0,256	0,999
E11 fenêtre 60 mois	CAC 40	Ridge : M1 contre M0	79	-4,0	-7,6	0,756	0,999
E11 fenêtre 60 mois	CAC 40	forêt : M1 contre M0	79	-14,0	-12,9	0,400	0,999
E11 fenêtre 60 mois	CAC 40	XGBoost : M1 contre M0	79	-45,4	-28,2	0,024	0,999
E12 par période	Δ spread	Ridge [2020-2021] : M1 contre M0	24	7,6	-1,4	0,957	—
E12 par période	Δ spread	Ridge [2022-2026] : M1 contre M0	55	-28,0	-22,5	0,230	—
E12 par période	Δ spread	Ridge [VIX ≤ 20] : M1 contre M0	46	-10,9	-7,9	0,295	—
E12 par période	Δ spread	Ridge [VIX > 20] : M1 contre M0	33	-27,1	-35,8	0,783	—
E12 par période	Δ spread	forêt [2020-2021] : M1 contre M0	24	-3,7	-7,9	0,804	—
E12 par période	Δ spread	forêt [2022-2026] : M1 contre M0	55	-8,6	-8,7	0,512	—
E12 par période	Δ spread	forêt [VIX ≤ 20] : M1 contre M0	46	-3,2	-5,1	0,738	—
E12 par période	Δ spread	forêt [VIX > 20] : M1 contre M0	33	-18,0	-18,7	0,536	—
E12 par période	Δ spread	XGBoost [2020-2021] : M1 contre M0	24	-26,7	-39,7	0,726	—
E12 par période	Δ spread	XGBoost [2022-2026] : M1 contre M0	55	-40,5	-24,5	0,064	—
E12 par période	Δ spread	XGBoost [VIX ≤ 20] : M1 contre M0	46	-24,0	-22,4	0,440	—
E12 par période	Δ spread	XGBoost [VIX > 20] : M1 contre M0	33	-70,5	-54,0	0,260	—
E12 par période	Δ OAT	Ridge [2020-2021] : M1 contre M0	24	-13,7	-15,1	0,563	—
E12 par période	Δ OAT	Ridge [2022-2026] : M1 contre	55	-11,0	-10,7	0,473	—

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		M0					
E12 par période	Δ OAT	Ridge [VIX ≤ 20] : M1 contre M0	46	-16,4	-10,0	0,200	—
E12 par période	Δ OAT	Ridge [VIX > 20] : M1 contre M0	33	-8,2	-12,0	0,892	—
E12 par période	Δ OAT	forêt [2020-2021] : M1 contre M0	24	-0,9	7,7	0,229	—
E12 par période	Δ OAT	forêt [2022-2026] : M1 contre M0	55	-7,8	-9,0	0,620	—
E12 par période	Δ OAT	forêt [VIX ≤ 20] : M1 contre M0	46	-20,2	-14,6	0,223	—
E12 par période	Δ OAT	forêt [VIX > 20] : M1 contre M0	33	1,2	-2,2	0,799	—
E12 par période	Δ OAT	XGBoost [2020-2021] : M1 contre M0	24	-24,3	-22,4	0,456	—
E12 par période	Δ OAT	XGBoost [2022-2026] : M1 contre M0	55	-31,1	-31,5	0,524	—
E12 par période	Δ OAT	XGBoost [VIX ≤ 20] : M1 contre M0	46	-48,8	-36,3	0,106	—
E12 par période	Δ OAT	XGBoost [VIX > 20] : M1 contre M0	33	-18,8	-26,8	0,808	—
E12 par période	CAC 40	Ridge [2020-2021] : M1 contre M0	24	-0,5	-0,7	0,664	—
E12 par période	CAC 40	Ridge [2022-2026] : M1 contre M0	55	-2,2	-6,5	0,804	—
E12 par période	CAC 40	Ridge [VIX ≤ 20] : M1 contre M0	46	-1,3	-1,0	0,278	—
E12 par période	CAC 40	Ridge [VIX > 20] : M1 contre M0	33	-1,4	-5,6	0,834	—
E12 par période	CAC 40	forêt [2020-2021] : M1 contre M0	24	-11,0	-11,2	0,512	—
E12 par période	CAC 40	forêt [2022-2026] : M1 contre M0	55	-8,1	-10,3	0,737	—
E12 par période	CAC 40	forêt [VIX ≤ 20] : M1 contre M0	46	-12,8	-11,4	0,372	—
E12 par période	CAC 40	forêt [VIX > 20] : M1	33	-7,0	-10,3	0,702	—

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
		contre M0					
E12 par période	CAC 40	XGBoost [2020-2021] : M1 contre M0	24	-27,8	-34,6	0,740	—
E12 par période	CAC 40	XGBoost [2022-2026] : M1 contre M0	55	-35,9	-20,4	0,097	—
E12 par période	CAC 40	XGBoost [VIX ≤ 20] : M1 contre M0	46	-26,2	-34,7	0,902	—
E12 par période	CAC 40	XGBoost [VIX > 20] : M1 contre M0	33	-36,1	-22,2	0,149	—
E13 notations	Δ spread	Ridge : M1 + notations contre M0 + notations	79	-8,8	-8,6	0,475	0,999
E13 notations	Δ spread	forêt : M1 + notations contre M0 + notations	79	-5,7	-9,2	0,827	0,999
E13 notations	Δ spread	XGBoost : M1 + notations contre M0 + notations	79	-35,5	-27,5	0,195	0,999
E13 notations	Δ OAT	Ridge : M1 + notations contre M0 + notations	79	-8,9	-11,0	0,785	0,999
E13 notations	Δ OAT	forêt : M1 + notations contre M0 + notations	79	-5,2	-6,8	0,673	0,999
E13 notations	Δ OAT	XGBoost : M1 + notations contre M0 + notations	79	-27,3	-36,3	0,832	0,999
E13 notations	CAC 40	Ridge : M1 + notations contre M0 + notations	79	0,0	-21,4	0,901	0,999
E13 notations	CAC 40	forêt : M1 + notations contre M0 + notations	79	-9,8	-10,8	0,609	0,999
E13 notations	CAC 40	XGBoost : M1 + notations contre M0 + notations	79	-34,1	-26,7	0,196	0,999
E15 panel trimestriel	Δ spread trimestriel (5 pays)	Ridge : M1 contre M0	330	13,9	15,5	0,365	0,999
E15 panel trimestriel	Δ spread trimestriel	forêt : M1 contre M0	330	-5,3	4,0	0,057	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
	(5 pays)						
E15 panel trimestriel	Δ spread trimestriel (5 pays)	XGBoost : M1 contre M0	330	-29,3	-2,9	0,047	0,999
E16 répliation élargie	Spread (variation)	forêt : complet contre sans finances publiques	874	-3,7	-3,8	0,527	0,999
E16 répliation élargie	Spread (variation)	Ridge : complet contre sans finances publiques	874	-238,2	-162,8	0,079	0,999
E16 répliation élargie	Spread (variation)	XGBoost : complet contre sans finances publiques	874	-12,4	-13,1	0,586	0,999
E16 répliation élargie	Spread (niveau)	forêt : complet contre sans finances publiques	874	94,8	94,5	0,814	0,999
E16 répliation élargie	Spread (niveau)	Ridge : complet contre sans finances publiques	874	90,0	92,4	0,121	0,999
E16 répliation élargie	Spread (niveau)	XGBoost : complet contre sans finances publiques	874	97,0	97,0	0,392	0,999
E17 panel annuel	Δ spread annuel (5 pays)	Ridge : M1 contre M0	75	-330,6	-338,4	0,753	0,999
E17 panel annuel	Δ spread annuel (5 pays)	forêt : M1 contre M0	75	-45,4	-19,8	0,039	0,999
E17 panel annuel	Δ spread annuel (5 pays)	XGBoost : M1 contre M0	75	-108,1	-51,5	0,077	0,999
E18 régime de crise (exploratoire)	Δ spread trimestriel fin de trimestre (5 pays)	Ridge : M1 contre M0	330	-3,3	-19,7	0,816	0,999
E18 régime de crise (exploratoire)	Δ spread trimestriel fin de trimestre (5 pays)	forêt : M1 contre M0	330	-10,4	-4,9	0,195	0,999
E18 régime de crise (exploratoire)	Δ spread trimestriel fin de trimestre (5 pays)	XGBoost : M1 contre M0	330	-20,2	-26,2	0,719	0,999
E18 ventilation (hors	Δ spread trimestriel fin de	Ridge : M1 contre M0, 2010-2014	100	-4,1	-22,4	0,799	—

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
correction)	trimestre (5 pays)						
E18 ventilation (hors correction)	Δ spread trimestriel fin de trimestre (5 pays)	Ridge : M1 contre M0, 2015+	230	1,1	-4,3	0,875	—
E18 ventilation (hors correction)	Δ spread trimestriel fin de trimestre (5 pays)	forêt : M1 contre M0, 2010-2014	100	-12,4	-5,2	0,169	—
E18 ventilation (hors correction)	Δ spread trimestriel fin de trimestre (5 pays)	forêt : M1 contre M0, 2015+	230	0,8	-3,3	0,675	—
E18 ventilation (hors correction)	Δ spread trimestriel fin de trimestre (5 pays)	XGBoost : M1 contre M0, 2010-2014	100	-20,3	-28,2	0,744	—
E18 ventilation (hors correction)	Δ spread trimestriel fin de trimestre (5 pays)	XGBoost : M1 contre M0, 2015+	230	-19,7	-14,4	0,365	—
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	Ridge h=1 : M1 contre M0	79	-0,0	-1,2	0,844	0,999
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	forêt h=1 : M1 contre M0	79	-5,3	-9,9	0,950	0,999
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	XGBoost h=1 : M1 contre M0	79	-18,6	-31,5	0,968	0,999
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	Ridge h=3 : M1 contre M0	77	-6,4	-23,7	0,962	0,999
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	forêt h=3 : M1 contre M0	77	1,4	-0,7	0,686	0,999
E19 actions sectorielles	BTP-concessions (excès sur le CAC 40)	XGBoost h=3 : M1 contre M0	77	-8,8	-8,7	0,495	0,999
E19 actions sectorielles	Défense (excès sur le CAC 40)	Ridge h=1 : M1 contre M0	79	-0,0	-1,7	0,728	0,999
E19 actions sectorielles	Défense (excès sur le CAC 40)	forêt h=1 : M1 contre M0	79	-6,3	-6,0	0,455	0,999
E19 actions sectorielles	Défense (excès sur le CAC 40)	XGBoost h=1 : M1 contre M0	79	-13,2	-11,6	0,417	0,999
E19 actions	Défense	Ridge h=3 :	77	-10,1	-65,8	0,927	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
sectorielles	(excès sur le CAC 40)	M1 contre M0					
E19 actions sectorielles	Défense (excès sur le CAC 40)	forêt h=3 : M1 contre M0	77	-19,4	-10,8	0,061	0,999
E19 actions sectorielles	Défense (excès sur le CAC 40)	XGBoost h=3 : M1 contre M0	77	-53,3	-19,9	0,008	0,999
E20a incertitude politique	Δ spread	Ridge : M0+EPU contre M0	79	-14,9	-13,6	0,187	0,999
E20a incertitude politique	Δ spread	forêt : M0+EPU contre M0	79	-6,8	-6,1	0,313	0,999
E20a incertitude politique	Δ spread	XGBoost : M0+EPU contre M0	79	-35,4	-38,9	0,818	0,999
E20a incertitude politique	Δ OAT	Ridge : M0+EPU contre M0	79	-11,3	-8,7	0,134	0,999
E20a incertitude politique	Δ OAT	forêt : M0+EPU contre M0	79	-6,9	-4,8	0,136	0,999
E20a incertitude politique	Δ OAT	XGBoost : M0+EPU contre M0	79	-30,2	-32,8	0,706	0,999
E20a incertitude politique	CAC 40	Ridge : M0+EPU contre M0	79	-1,3	-0,3	0,208	0,999
E20a incertitude politique	CAC 40	forêt : M0+EPU contre M0	79	-9,6	-12,0	0,990	0,999
E20a incertitude politique	CAC 40	XGBoost : M0+EPU contre M0	79	-31,7	-38,6	0,972	0,999
E20b dépenses + incertitude	Δ spread	Ridge : M1+EPU contre M0+EPU	79	-13,6	-13,9	0,529	0,999
E20b dépenses + incertitude	Δ spread	forêt : M1+EPU contre M0+EPU	79	-6,1	-7,5	0,684	0,999
E20b dépenses + incertitude	Δ spread	XGBoost : M1+EPU contre M0+EPU	79	-38,9	-31,9	0,284	0,999
E20b dépenses + incertitude	Δ OAT	Ridge : M1+EPU contre M0+EPU	79	-8,7	-10,7	0,734	0,999
E20b dépenses + incertitude	Δ OAT	forêt : M1+EPU contre M0+EPU	79	-4,8	-5,9	0,637	0,999
E20b dépenses + incertitude	Δ OAT	XGBoost : M1+EPU contre M0+EPU	79	-32,8	-30,2	0,310	0,999
E20b	CAC 40	Ridge :	79	-0,3	-2,6	0,904	0,999

Extension	Cible	Comparaison	n	R ² sans (%)	R ² avec (%)	p brute	p corrigée (BH)
dépenses + incertitude		M1+EPU contre M0+EPU					
E20b dépenses + incertitude	CAC 40	forêt : M1+EPU contre M0+EPU	79	-12,0	-11,2	0,416	0,999
E20b dépenses + incertitude	CAC 40	XGBoost : M1+EPU contre M0+EPU	79	-38,6	-29,6	0,134	0,999

Source : *results/tables/ext_summary.csv*.

Annexe C – Sensibilité à la graine aléatoire

Tableau C.1 – R² hors échantillon (%) selon la graine

Modèle	Cible	R ² M0 (min à max)	R ² M1 (min à max)	Plus petite p DM (M1 contre M0)
Forêt aléatoire (5 graines)	Δ spread	-6,3 à -3,3	-9,7 à -6,2	0,13
Forêt aléatoire (5 graines)	Δ OAT	-6,6 à -5,1	-8,0 à -6,9	0,50
Forêt aléatoire (5 graines)	CAC 40	-11,5 à -8,4	-10,7 à -7,1	0,52
XGBoost (10 graines)	Δ spread	-39,8 à -30,8	-32,9 à -25,4	0,14
XGBoost (10 graines)	Δ OAT	-33,5 à -27,8	-35,4 à -27,6	0,46
XGBoost (10 graines)	CAC 40	-39,1 à -30,3	-32,0 à -25,1	0,16

Source : *results/tables/diag_04/graines_rf.csv, graines_xgb.csv*.

Annexe D – Contrôle négatif : dépenses contre variables de bruit

Tableau D.1 – Gain de R² par rapport à M0 (points) : vraies dépenses et sept variables de bruit

Modèle	Cible	Tirages	Dépenses réelles	Bruit (min à max)	Tirages de bruit ≥ dépenses
Ridge	Δ spread	20	0,2	-2,6 à 10,8	90 %
Ridge	Δ OAT	20	0,0	-2,8 à 6,2	90 %
Ridge	CAC 40	20	-2,2	-3,3 à 1,9	95 %
Forêt aléatoire	Δ spread	5	-1,7	-3,2 à 4,4	80 %
Forêt aléatoire	Δ OAT	5	0,0	1,0 à 5,4	100 %
Forêt aléatoire	CAC 40	5	-1,1	-0,5 à 6,3	100 %
XGBoost	Δ spread	10	5,3	-6,3 à 15,4	50 %
XGBoost	Δ OAT	10	-0,2	-10,4 à 13,9	60 %
XGBoost	CAC 40	10	3,8	-6,0 à 18,0	50 %

Source : *results/tables/diag_04/bruit_*.csv*.

Annexe E – Robustesse au décalage de publication

Tableau E.1 – Modèles principaux avec un décalage budgétaire de 1, 2 et 3 mois

Décalage (mois)	Cible	Modèle	R ² M0 (%)	R ² M1 (%)	p DM bilatérale (M1 contre M0)	p corrigée (BH, unilatérale)
1	Δ spread	Ridge	-15,2	-18,9	0,46	0,97
1	Δ spread	forêt	-3,9	-10,4	0,06	0,97
1	Δ spread	XGBoost	-29,7	-41,3	0,30	0,97
1	Δ OAT	Ridge	-10,9	-11,2	0,96	0,85
1	Δ OAT	forêt	-5,5	-4,2	0,78	0,81
1	Δ OAT	XGBoost	-26,6	-19,3	0,56	0,81
1	CAC 40	Ridge	-1,4	-0,7	0,62	0,81
1	CAC 40	forêt	-9,7	-9,3	0,91	0,82
1	CAC 40	XGBoost	-37,2	-34,2	0,78	0,81
2	Δ spread	Ridge	-14,9	-14,7	0,97	0,81
2	Δ spread	forêt	-6,8	-8,4	0,58	0,85
2	Δ spread	XGBoost	-35,4	-30,1	0,61	0,81
2	Δ OAT	Ridge	-11,3	-11,3	0,99	0,81
2	Δ OAT	forêt	-6,9	-6,9	0,99	0,81
2	Δ OAT	XGBoost	-30,2	-30,4	0,98	0,81
2	CAC 40	Ridge	-1,3	-3,5	0,37	0,87
2	CAC 40	forêt	-9,6	-10,8	0,77	0,81
2	CAC 40	XGBoost	-31,7	-27,8	0,63	0,81
3	Δ spread	Ridge	-14,2	-24,4	0,14	0,99
3	Δ spread	forêt	-5,2	-5,7	0,87	0,89
3	Δ spread	XGBoost	-35,0	-31,3	0,60	0,68
3	Δ OAT	Ridge	-12,2	-14,5	0,61	0,90
3	Δ OAT	forêt	-7,5	-3,7	0,32	0,51
3	Δ OAT	XGBoost	-28,4	-11,9	0,09	0,51
3	CAC 40	Ridge	-4,2	-2,7	0,33	0,51
3	CAC 40	forêt	-9,4	-11,4	0,49	0,91
3	CAC 40	XGBoost	-32,2	-35,5	0,63	0,90

Source : *results/tables/robustesse_lag.csv*. La correction BH porte sur les p-values unilatérales « avec dépenses meilleur que sans » ; elle peut donc être inférieure à la p-value bilatérale affichée.

Annexe F – Code et reproductibilité

Le code, les données et les résultats sont conservés dans le dépôt GitHub du projet (lyaminedb1/public-spending-market-prediction, accessible sur demande). Le script `run_all.sh` relance l'ensemble de la chaîne ; les versions des bibliothèques logicielles sont figées dans `requirements.txt` et les fichiers de données brutes dans `data/MANIFEST.csv`. Le script `tests/verifications.py` exécute 63 contrôles automatiques (alignement des cibles, décalages de publication, absence de fuite d'information dans la validation glissante, mois incomplets). Les valeurs exactes des forêts aléatoires et de

XGBoost peuvent varier légèrement selon les versions des bibliothèques logicielles ; les conclusions n'en dépendent pas.